PROYECTO INTEGRADOR · UNIDAD II

MatriScope

Sistema inteligente para comparar evidencia científica sobre defectos en materiales

Propuesta integral de investigación, diseño de producto y arquitectura de software

ASIGNATURA Tópicos Selectos de Arquitectura de Software

ESTUDIANTE Montserrat Viridiana Ramos López

MODALIDAD Individual

FECHA 6 de noviembre de 2026

Resumen ejecutivo

MatriScope es una propuesta de desarrollo de software científico orientada a transformar una colección autorizada de artículos sobre porosidad en acero inoxidable 316L fabricado mediante fusión láser de lecho de polvo (LPBF) en una matriz de evidencia estructurada, auditable y exportable. El producto reunirá ingesta documental, extracción contextual de afirmaciones, recuperación aumentada por generación (RAG), comparación condicionada por variables experimentales, revisión humana y emisión de informes. Su resultado principal será un artefacto de análisis —no una conversación— en el que cada conclusión remita a la fuente y al pasaje que la sustenta.

El problema científico de partida tiene fundamento documental: NIST describe la necesidad de mejores datos, mediciones y relaciones proceso–estructura–propiedades en manufactura aditiva; Anwar et al. (2025) estudian la formación de defectos en SS316L bajo variaciones de parámetros y velocidad de fabricación incluso al mantener una densidad energética volumétrica nominal constante. Estos antecedentes justifican conservar variables y condiciones antes de contrastar hallazgos. No se presupone que el corpus contenga resultados contradictorios; identificarlos, si existen, será una tarea empírica del sistema y de su revisor.

La presente versión delimita el producto, sus pantallas y módulos, un modelo de información, las reglas de decisión, su arquitectura en capas y una estrategia de validación reproducible. Es una especificación prospectiva: los diagramas de interfaz son diseños conceptuales; las métricas, comparaciones de modelos y resultados de extracción deberán producirse mediante experimentación y no se presentan como hechos ya obtenidos.

1 Identidad y definición de la propuesta

Tabla 1. Delimitación del producto y propuesta de valor

Elemento	Definición propuesta
Nombre del producto	MatriScope, analizador local de evidencia científica.
Usuario y contexto	Investigador o estudiante que realiza revisión bibliográfica sobre porosidad en manufactura aditiva metálica.
Problema	La comparación de hallazgos requiere identificar material, técnica, condiciones, variable medida y resultado; sin ese contexto, las diferencias pueden interpretarse incorrectamente.
Resultado concreto	Matriz de evidencia con citas y reporte PDF de coincidencias, divergencias potenciales y vacíos relativos al corpus.
Tipo de producto	Extractor científico + explorador semántico + verificador de consistencia documental.
Papel de IA, embeddings y RAG	Embeddings recuperan fragmentos; RAG integra fuentes; LLM extrae afirmaciones y propone categorías comparativas verificables.
Originalidad de la propuesta	Conecta cada conclusión con condiciones experimentales y distingue contradicción posible de evidencia no comparable.
Medición de valor	Calidad de extracción, acierto@k, exactitud de citas, precisión de alertas, tiempo de análisis y utilidad reportada por usuarios.

2 Planteamiento del problema

La manufactura aditiva metálica permite construir componentes con geometrías complejas, pero su calidad está condicionada por variaciones de proceso y por la interacción entre fabricación, microestructura y propiedades. NIST (2026) señala retos de variabilidad, caracterización y calificación de materiales. Para el acero 316/316L, Aziz et al. (2025) documentan que la potencia láser, velocidad de escaneo, espesor de capa, orientación y tratamientos posteriores están relacionados con la formación y mitigación de defectos. Stopka et al. (2024) argumentan, en un trabajo sobre componentes limitados por fatiga, que es necesario considerar tamaño, morfología y distribución de poros al interpretar resultados.

Estas publicaciones no demuestran que los estudios seleccionados para MatriScope se contradigan entre sí. Fundamentan algo más preciso: cualquier comparación bibliográfica sobre defectos debe preservar sus condiciones. El problema informático consiste en recuperar afirmaciones dispersas en los artículos y organizarlas de modo que un investigador pueda comprobar si dos conclusiones son compatibles, diferentes o no comparables.

3 Justificación científica y tecnológica

La propuesta tiene relevancia científica como apoyo a la revisión documental, no como instrumento de medición física de porosidad. Una matriz vinculada a sus fragmentos originales facilitará revisar afirmaciones y detectar preguntas que requieren lectura adicional. Su contribución tecnológica consiste en integrar extracción estructurada, búsqueda vectorial, análisis contextual y trazabilidad en un flujo local. Lewis et al. (2020) presentaron RAG como una arquitectura que combina generación con recuperación de conocimiento externo; MatriScope empleará esa lógica para fundamentar reportes, sin asumir que RAG elimina por sí solo errores o alucinaciones.

Se eligió un alcance documental en lugar de clasificación automática de micrografías porque la detección visual de defectos sería otro problema experimental, con datos etiquetados y validación de visión artificial. Las imágenes y tablas no extraíbles se señalarán como limitación; no se les asignará contenido mediante inferencia.

4 Pregunta de trabajo y objetivos

Pregunta orientadora. ¿Puede un servicio local basado en embeddings y RAG organizar afirmaciones científicas sobre porosidad en acero inoxidable 316L y señalar diferencias entre estudios sin omitir las condiciones que determinan su comparabilidad?

Objetivo general. Diseñar, implementar y evaluar una aplicación web que extraiga, contraste y documente evidencia científica sobre porosidad en manufactura aditiva de acero 316L mediante modelos de lenguaje locales, recuperación semántica y una arquitectura de servicio en capas.

- Seleccionar un corpus autorizado y documentar procedencia, licencia, técnica de fabricación y metadatos bibliográficos.
- Fragmentar e indexar artículos, comparar dos embeddings y recuperar evidencia identificable por fuente y página.
- Extraer afirmaciones con campos de material, proceso, defecto, variable, resultado, unidad y condición experimental.
- Clasificar pares de afirmaciones como compatibles, divergencia potencial, no comparables o evidencia insuficiente, con revisión de citas.
- Implementar API, aplicación web, capas obligatorias, observabilidad y retroalimentación.
- Evaluar calidad y desempeño del producto frente a casos de referencia revisados manualmente.

5 Concepto del producto y público objetivo

El producto atenderá a una persona que realiza una revisión de literatura científica: estudiante de posgrado, asistente de investigación o investigador especializado en materiales. Su momento de uso será posterior a la selección de publicaciones y anterior a la redacción de una síntesis científica. El usuario necesita comparar conclusiones sin confundir diferencias de medición, proceso o material con desacuerdos sustantivos.

MatriScope se concibe como un banco de trabajo documental. El usuario crea un proyecto de revisión, integra sus fuentes, define qué variable y tipo de defecto desea examinar, solicita un mapa de evidencia y revisa cada par de afirmaciones. Puede corregir extracciones y exportar un informe que diferencie hallazgos confirmados, hipótesis por revisar y ausencia de evidencia. La interfaz no colocará un chat en el centro del producto: la operación principal será “Construir mapa de evidencia”.

Tabla 2. Perfiles de uso y responsabilidades previstas

Actor	Necesidad principal	Permisos contemplados
Investigador responsable	Definir alcance, seleccionar trabajos, interpretar comparaciones y aprobar el informe.	Crear proyectos, cargar y excluir documentos, ejecutar análisis, confirmar o corregir y exportar.
Revisor académico	Verificar citas y reproducibilidad de una matriz preparada.	Consultar, filtrar y anotar; no alterar el corpus de origen sin autorización.
Operador técnico local	Verificar disponibilidad y calidad operacional del servicio.	Consultar métricas, modelos, configuración y registros técnicos.

En el primer prototipo local la autenticación multiusuario podrá limitarse a perfiles lógicos. No se presentará la separación de roles como seguridad implementada mientras no exista autorización efectiva en el servicio. El alcance mínimo plenamente verificable será un investigador responsable operando en una estación local.

6 Estructura funcional del sistema

El producto se dividirá en módulos con responsabilidades concretas y estado visible. Las operaciones deben poder reproducirse desde una interfaz web que consuma exclusivamente el servicio REST. Los módulos de investigación no llamarán directamente al modelo local ni a la base vectorial.

Tabla 3. Inventario de módulos y resultados del producto

Módulo	Funciones previstas	Resultado visible
M01 Proyectos	Crear proyecto; fijar pregunta, material, proceso y versión de corpus.	Ficha de revisión y estado.
M02 Biblioteca	Cargar PDF; registrar DOI, licencia, autores, año; validar y excluir archivos; detectar duplicados.	Inventario con procedencia y advertencias.
M03 Indexación	Extraer texto, conservar página/sección, fragmentar, vectorizar y versionar índice.	Progreso, fragmentos y errores de ingesta.
M04 Explorador	Consultar por variable, proceso, defecto y método; ver documentos y pasajes recuperados.	Listado de fuentes y fragmentos rastreables.
M05 Extracción	Detectar afirmaciones candidatas y convertirlas a registros tipados; someterlas a verificación.	Fichas de afirmaciones, campos ausentes.

Módulo	Funciones previstas	Resultado visible
M06 Comparador	Emparejar afirmaciones potencialmente pertinentes, revisar condiciones y proponer relación.	Matriz con estados y justificación.
M07 Validación	Abrir fragmento original, aprobar/corregir/desestimar, registrar observación y traza.	Historial de decisiones de revisión.
M08 Informes	Filtrar resultados y exportar PDF con alcance, metodología, matriz, citas y límites.	Archivo PDF descargable.
M09 Operación	Mostrar salud, caché, rutas de modelos, latencia, feedback y eventos.	Panel de métricas y trazas.
M10 Configuración	Configurar candidatos de LLM, embeddings, top-k, umbral y política de abstención.	Configuración registrada por versión.

La unidad funcional básica es el proyecto de revisión. Un documento puede contener varias afirmaciones, una afirmación puede aportar evidencia a varias comparaciones y cada comparación conservará los identificadores de las fuentes utilizadas. Las correcciones humanas no sobrescribirán el texto original: crearán una versión revisada que conserve procedencia y autoría de la decisión.

7 Proceso de uso y decisiones del investigador

1. Inicio y definición: crear un proyecto, registrar una pregunta específica (por ejemplo, relación entre parámetros de LPBF y porosidad en 316L), decidir el universo documental y guardar sus criterios de inclusión/exclusión.
2. Curaduría: incorporar solo publicaciones con procedencia verificable; comprobar condiciones de uso; marcar documentos dudosos, repetidos, incompletos o ilegibles.
3. Preparación: extraer texto de cada documento, conservar referencias a páginas y metadatos, fragmentar e indexar con un embedding elegido; registrar versión y parámetros.
4. Construcción del análisis: seleccionar variable y filtros, recuperar pasajes, obtener afirmaciones candidatas y normalizar campos sin inventar los faltantes.
5. Comparación condicionada: establecer si existe base suficiente para cotejar material, proceso, método, unidad y contexto; emitir una clase preliminar o abstenerse.
6. Revisión y consolidación: abrir citas en su contexto, confirmar/corregir/descartar hallazgos, incluir observaciones del revisor y recalcular la matriz si cambia el corpus.
7. Publicación: generar informe PDF versionado con tabla de afirmaciones, parejas, respaldo y limitaciones, identificando los resultados que aún carecen de validación humana.

Estados del análisis: BORRADOR → CORPUS_PREPARADO → EN_PROCESO → REQUIERE_REVISION → VALIDADO → EXPORTADO. Un fallo de ingesta o del modelo dejará el proceso en estado recuperable y registrará el error; no transformará un resultado incompleto en un análisis validado. El sistema permitirá repetir una versión con configuración fijada para analizar reproducibilidad.

8 Diseño de experiencia e interfaz de usuario

Se propone una aplicación web de escritorio con navegación lateral persistente, cabecera de proyecto, área central de trabajo y controles de estado. La paleta será sobria —azules desaturados, fondo claro y tipografía legible— para dar prioridad a tablas, metadatos y documentos. Cada pantalla incluirá señales explícitas de carga, éxito, advertencia, ausencia de resultados y falla técnica. Ningún componente visual declarará “evidencia validada” por el solo hecho de que un LLM la haya generado.

8.1 Biblioteca y preparación del corpus

La vista de biblioteca muestra documentos, DOI, licencia o permiso, extracción de texto, estado de indexación y posibilidad de inspeccionar metadatos. Al cargar un archivo, el formulario solicitará fuente, licencia, documento original y pertinencia; el servicio validará tipo, tamaño, duplicidad y coherencia de metadatos. La selección será reversible y quedará registrada.

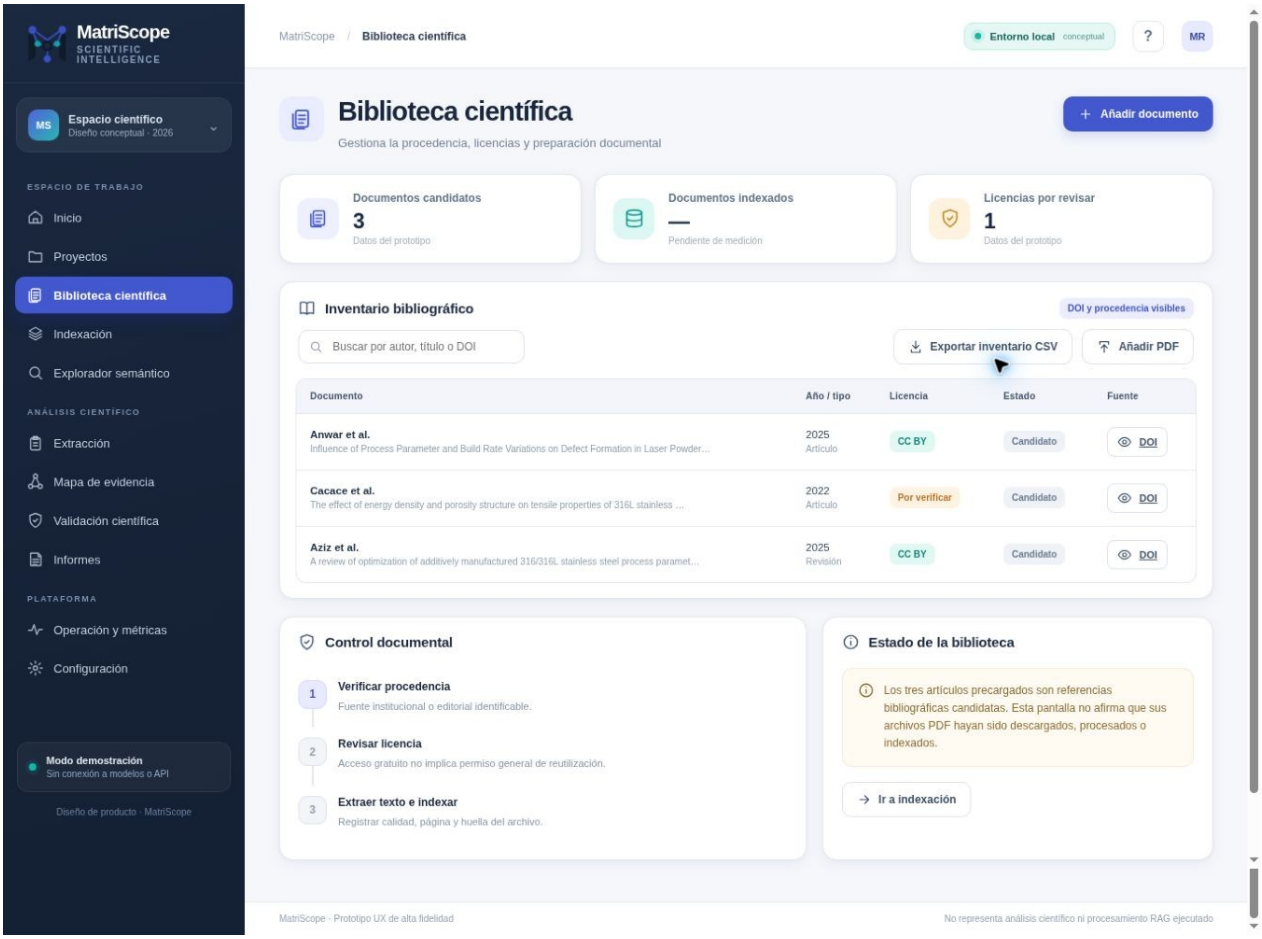


Figura 1. Vista definitiva de Biblioteca científica: inventario documental, metadatos y controles de procedencia. Prototipo de interfaz; las operaciones de ingesta se conectarán al servicio local.

8.2 Mapa de evidencia y comparación

La pantalla principal presenta filtros científicos, tabla de afirmaciones, agrupaciones y relaciones entre pares. Cada fila mostrará resumen, variables aplicables, clase preliminar, fuentes y estado de revisión. Un panel de lectura permitirá abrir un hallazgo sin perder la tabla general. Las divergencias se mostrarán como “potenciales” hasta que el revisor contraste los textos, y la interfaz distinguirá claramente entre información insuficiente y ausencia de discrepancias.

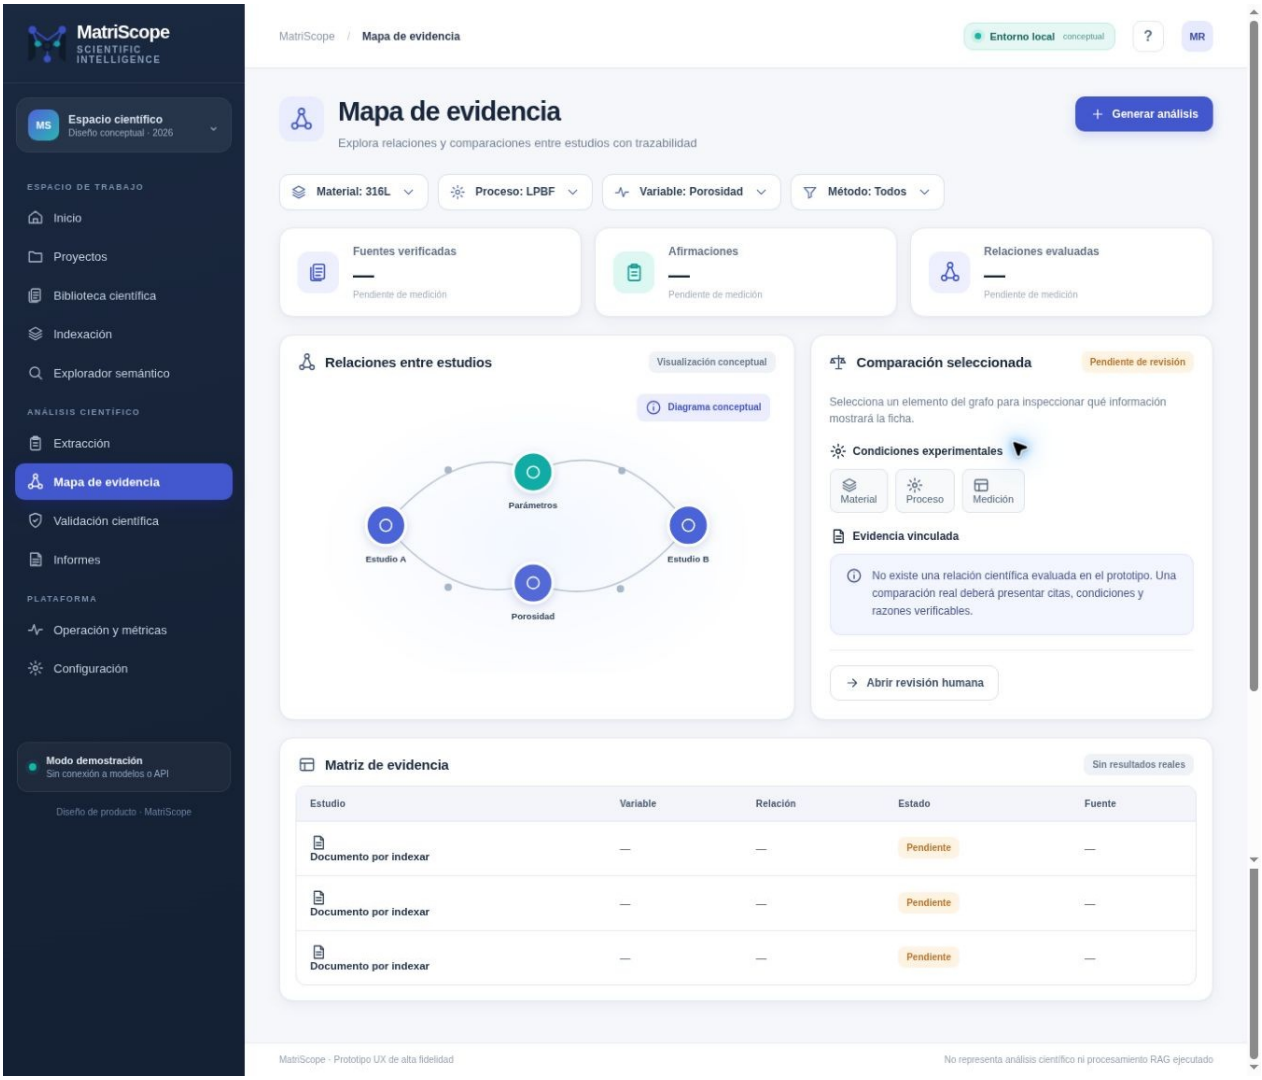


Figura 2. Vista definitiva del Mapa de evidencia: filtros, relaciones y matriz de comparación con fuentes. El esquema gráfico es ilustrativo y no constituye un resultado experimental.

8.3 Ficha de trazabilidad y revisión

La ficha de detalle presentará una afirmación y el fragmento exacto que la respalda. Junto a ella incluirá variables, unidades, sección/página, DOI y enlace al PDF origen. El investigador podrá aprobar, corregir o desestimar la extracción y justificar su decisión. Cada modificación conservará fecha, versión del proyecto e identificador de traza. Esta es la vista de control científico del producto.

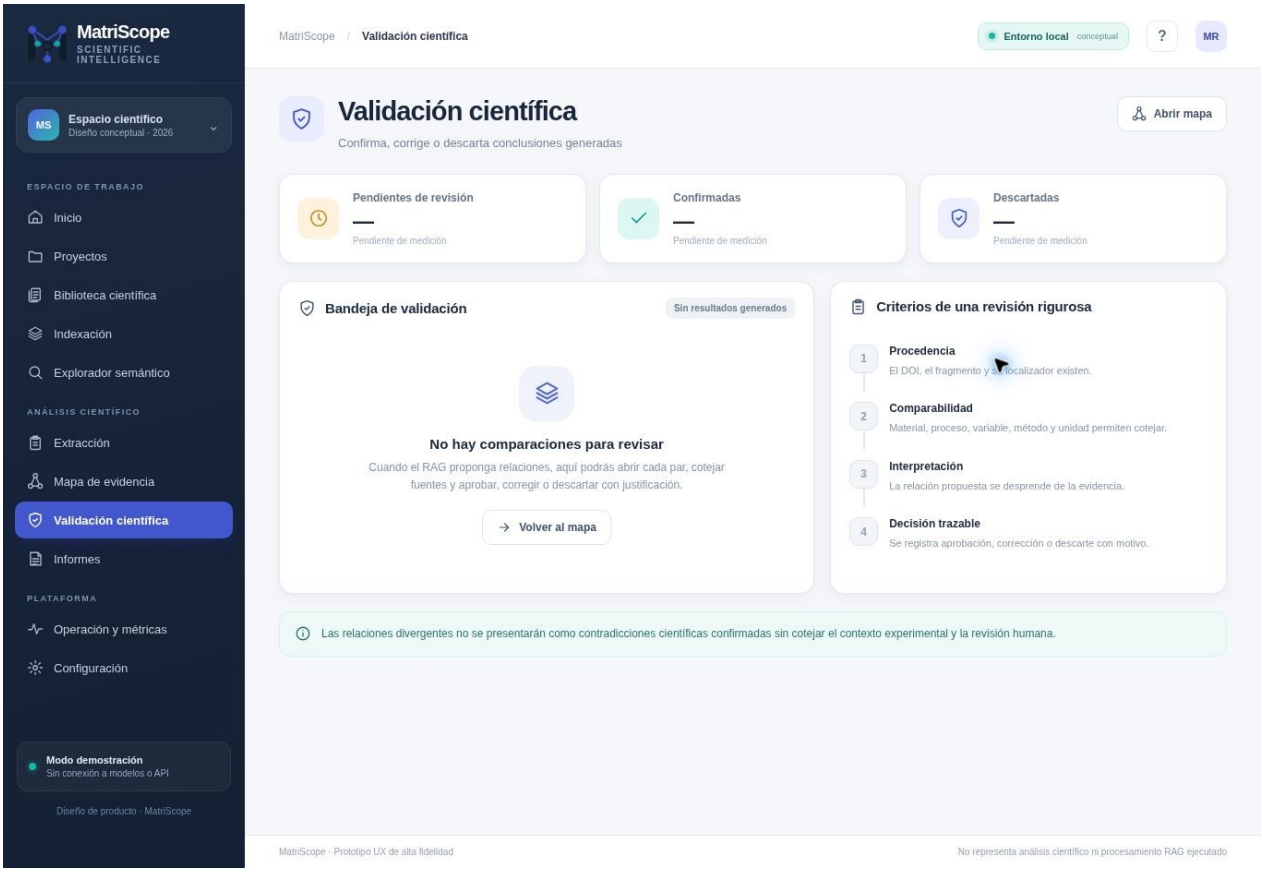


Figura 3. Vista definitiva de Validación científica: revisión de afirmaciones y consulta de fuentes. La aceptación de resultados requerirá evidencia real y registro auditable.

8.4 Resto del mapa de navegación

Tabla 4. Vistas complementarias y contenido mínimo

Pantalla	Componentes esenciales
Inicio	Proyectos recientes, estado del servicio, corpus activo, análisis abiertos y acceso a acciones prioritarias.
Crear análisis	Objetivo documental, selección de corpus, filtros de variable/defecto, opciones de ejecución y confirmación.
Informe	Portada, alcance, método, matriz, lista bibliográfica, advertencias y opciones de exportar.
Indicadores	Tiempos por operación, consultas, rutas de modelos, caché, recuperaciones débiles y errores.
Configuración	Modelos instalados, embedding vigente, índice, límites de iteración y parámetros de recuperación.

9 Alcance, corpus y reglas de interpretación

El dominio inicial serán publicaciones textuales sobre porosidad y parámetros de proceso en acero inoxidable 316L producido mediante fusión láser de lecho de polvo. Existe un inventario preliminar de artículos candidatos, pero su preselección no equivale a disponer de un corpus íntegramente autorizado, descargado o indexado. Antes de incorporarlos se verificará pertinencia, accesibilidad y permiso de reutilización. Se registrarán título, autores, año, DOI, URL, licencia, páginas y fecha de consulta.

PubMed Central aclara que la lectura gratuita de un artículo no equivale necesariamente a permiso general de reutilización y que la descarga sistemática tiene canales específicos (National Library of Medicine, 2025). Por ello se verificarán licencias individuales y se evitará descargar lotes desde el sitio principal. Como antecedentes comprobados, el trabajo de Aziz et al. (2025) está disponible bajo CC BY y el trabajo de Stopka et al. (2024) figura como acceso abierto; no se extenderá automáticamente esa condición a otras publicaciones.

Tabla 5. Campos científicos que gobiernan la comparabilidad

Campo de comparación	Regla de trabajo
Material	No comparar como equivalentes aceros o aleaciones diferentes sin declararlo.
Proceso	Registrar método y parámetros; distinguir técnicas distintas.
Defecto	Normalizar nombres como porosidad, falta de fusión o grieta, sin confundir fenómenos.
Medición	Conservar unidad, método, escala y dirección del resultado.
Evidencia	Toda afirmación requiere documento, página/sección y fragmento recuperado.
Clasificación	Solo “divergencia potencial” cuando variables y condiciones sean razonablemente comparables; en otro caso “no comparable”.

10 Metodología de desarrollo y tratamiento documental

8. Preparación del corpus: seleccionar documentos autorizados, extraer texto y tablas que puedan verificarse, limpiar encabezados y conservar metadatos de origen.
9. Indexación: comparar fragmentación por longitud y por sección; generar embeddings con dos modelos y construir índices separados.
10. Recuperación: ejecutar búsqueda semántica por defecto, proceso y variable; evaluar k y umbral con casos etiquetados antes de fijarlos.
11. Extracción: generar registros estructurados en JSON y contrastar automáticamente cada cita con los fragmentos consultados.
12. Comparación: filtrar pares candidatos por material/proceso/variable, recuperar evidencia adicional y marcar compatibilidad o incertidumbre.
13. Producción del resultado: presentar matriz navegable con fuentes y permitir descargar un informe PDF de resultados verificados.
14. Evaluación: medir calidad de recuperación, fidelidad al corpus, clasificaciones, latencia y comportamiento de las capas.

11 Arquitectura técnica y separación de responsabilidades

La propuesta mantendrá dos contenedores lógicos, interfaz web y servicio REST. Ollama, la base vectorial y los almacenes operarán en el equipo local como dependencias del servicio. La web solo consumirá la API por HTTP. FastAPI ofrece generación de documentación OpenAPI (FastAPI, s. f.) y Chroma permite colecciones con funciones de embeddings (Chroma, s. f.), capacidades útiles para los adaptadores propuestos.

Se adoptará una dependencia dirigida hacia abstracciones: rutas HTTP → casos de uso → servicios de dominio y puertos → adaptadores de infraestructura. Los componentes transversales de seguridad, caché, observabilidad y retroalimentación se invocarán en pasos definidos, sin acoplar las reglas científicas a Chroma o a una familia particular de modelos. Este diseño facilita sustituir un adaptador durante las comparaciones experimentales sin reescribir la lógica de análisis.

Tabla 6. Responsabilidad de los componentes de arquitectura

Capa	Responsabilidad verificable
C1 Interfaz API	Validación Pydantic, códigos HTTP, OpenAPI y endpoints documentados.
C2 Orquestación y agente	Coordina el análisis y, ante recuperación débil, reformula búsqueda con un máximo de iteraciones definido.
C3 Guardrails	Entrada: archivos y datos sensibles/inyección de instrucciones. Salida: esquema válido, fuentes existentes y ausencia de afirmaciones sin evidencia.
C4 Caché	Respuesta exacta y búsqueda semántica; umbral, vencimiento y versión del corpus, invalidados tras cambios.
C5 Construcción de contexto	Extracción, fragmentación, embeddings, top-k, filtros documentales y prompt con citas.
C6 Enrutador y gateway	Clasificación de complejidad; dos LLM, timeout, reintento y modelo alterno.
C7 Datos y modelos	Puertos y adaptadores para Ollama, Chroma, archivos, SQLite y registros.
T1 Observabilidad	ID de traza, métricas de latencia y eventos por capa; caché, modelos y errores.
T2 Retroalimentación	Útil/no útil y comentario asociado a cada análisis y su traza.

11.1 Descomposición y flujo técnico previsto

- Presentación web: cliente que carga, valida formularios y consume JSON/PDF mediante HTTP; no incorpora secretos ni acceso directo al modelo.
- API y políticas: validación de esquema y límites de entrada; resolución de proyecto/corpus, autorización lógica y generación de trace_id.
- Orquestador: caso de uso ConstruirMapa que ejecuta recuperación, extracción, comparación, revisión de condiciones y composición del resultado.
- Recuperación contextual: consulta a índice por embedding, filtros de metadatos, top-k, control de duplicados y compilación de fragmentos citables.
- Modelo y datos: selección por complejidad, gateway con timeout y respaldo; almacenamiento de artículos, versiones, afirmaciones, comparaciones y bitácoras.

Flujo normal: el cliente crea una solicitud → API valida → guardrail de entrada decide → caché busca una versión equivalente → orquestador construye contexto → router selecciona un modelo → el extractor devuelve JSON tipado → el comparador aplica reglas de comparabilidad → guardrail de salida comprueba fuentes y esquema → se persiste el resultado y se responde con trazabilidad. Si la recuperación resulta débil, el agente puede reformular una consulta dentro de un límite explícito; si no mejora, se abstiene.

Flujo de caché: la clave exacta y la aproximación semántica incluirán versión del corpus, embedding, filtros, prompt/configuración, modelo y política de interpretación. Los resultados con correcciones humanas o nuevos documentos no reutilizarán entradas anteriores incompatibles. El umbral de similitud y tiempo de vida se fijarán tras medir errores por reutilización, no por conveniencia.

11.2 Organización de componentes de software

Tabla 7. Estructura lógica propuesta para implementación desacoplada

Área técnica	Elementos previstos
api/	routes, request/response schemas, error mapping, OpenAPI.
application/	casos de uso: importar, indexar, extraer, comparar, validar, exportar.
domain/	entidades, estados, reglas de comparabilidad y políticas de abstención.
services/	orquestación, guardrails, caché, retrieval, router, composición PDF.
ports/ y adapters/	interfaces e implementaciones para LLM, embeddings, vectores, SQLite y archivos.
observability/ y tests/	trazas, métricas, conjuntos de referencia y pruebas automatizadas.
web/	pantallas, estado de consultas, cliente HTTP y manejo de errores.

12 Modelos, embeddings y estrategia experimental

Tabla 8. Alternativas tecnológicas previstas

Categoría	Candidatos	Criterios a medir
Generación local	llama3.2:3b y qwen2.5:3b	Exactitud de campos, apego a fuentes, JSON válido, duración, memoria y uso del español.
Embeddings	nomic-embed-text y bge-m3	Acierto@k con el mismo corpus y consultas, latencia, dimensiones y recursos.
Almacenamiento	ChromaDB y SQLite	Persistencia, metadatos, recuperación y trazabilidad.

La elección de candidatos obedece a disponibilidad local en Ollama (s. f.) y al interés de comparar calidad y consumo real en una computadora de 16 GB de RAM. No se afirmará que un candidato es superior sin datos medidos. BGE-M3 se describe en Chen et al. (2024) como un modelo de embeddings multilingüe; su ventaja concreta en este corpus se comprobará experimentalmente. Deben revisarse también las licencias: la variante qwen2.5:3b tiene condiciones distintas a otras variantes de Qwen2.5 (Ollama, s. f.).

13 Contratos de servicio y resultados esperados

Tabla 9. Operaciones de la API REST

Método y ruta	Propósito
GET /health	Estado de Ollama, base vectorial, servicio y caché.
POST /documentos	Ingesta con ID, metadatos y número de fragmentos.
GET /documentos	Inventario bibliográfico indexado.
DELETE /documentos/{id}	Borrado de vectores y de caché afectada.
POST /mapa-evidencia	Matriz de afirmaciones, comparaciones, citas, modelo, caché, guardrails, latencia y traza.
POST /retroalimentacion	Guardar voto y comentario por traza.
GET /metricas	Consultar latencia, rutas, cache hits y bloqueos.
GET /configuracion	Parámetros y modelos activos.
GET /mapas/{id}/pdf	Descargar informe científico estructurado.

13.1 Contrato de la operación científica principal

Solicitud POST /mapa-evidencia: project_id, corpus_version, pregunta_investigacion, filtros {material, proceso, defecto, variable, metodo}, configuracion {top_k, modelo, embedding, iteraciones_maximas} y modo_revision. Respuesta: analysis_id, state, query, claims[], comparisons[], evidence[], warnings[], trace_id, model_id, corpus_version, retrieval_config, cache_info y performance_ms. Los objetos científicos se regirán por esquemas tipados y cada referencia contendrá un identificador estable de fragmento.

Tabla 10. Esquema conceptual de la respuesta y datos de evidencia

Objeto	Campos de salida relevantes
Afirmación	claim_id; doc_id; claim_text; material; proceso; variable; resultado; unidad; método; condiciones; source_span_id; validation_status.
Comparación	pair_id; claim_ids[2]; relationship; rationale; controlled_fields[]; missing_fields[]; evidence_ids[]; reviewer_status.
Evidencia	span_id; document_id; DOI/URL; filename; page; section; start/end offset cuando sea posible; text_excerpt; hash.
Proveniencia técnica	trace_id; model_id; embedding_id; corpus_version; index_version; prompt_version; timestamp; latency_ms.
Advertencia	code; severity; stage; detail; affected_claim_ids[]; recommended_review_action.

Política HTTP: 201 para ingesta creada, 200 para consultas exitosas, 202 cuando un análisis asíncrono siga procesándose, 400/422 para solicitudes incorrectas, 404 para recursos ausentes, 409 para versiones incompatibles o duplicados, 413 para archivo fuera del límite y 503 cuando un modelo requerido no esté disponible. Los errores devolverán código estable, descripción y trace_id, sin exponer rutas locales sensibles.

13.2 Modelo de persistencia, integridad y procedencia

Se prevén entidades Proyecto, Documento, Fragmento, Índice, Afirmación, Comparación, Revisión, Análisis, Informe, Configuración, Feedback y Traza. Documento–Fragmento y Proyecto–Análisis serán relaciones uno a muchos; Comparación relacionará dos afirmaciones, con sus evidencias independientes. El PDF original y sus huellas se conservarán separados de las extracciones y del índice vectorial; SQLite resguardará el historial transaccional y Chroma las representaciones semánticas.

Una fuente citada tendrá DOI o URL verificable, identificador interno, texto literal recuperado y localizador de página o sección cuando el método de extracción lo permita. Cuando el origen no proporcione página confiable, el campo se marcará como desconocido; nunca se inferirá una página. Los valores cuantitativos conservarán el texto numérico original, la unidad declarada y una normalización documentada solo cuando exista equivalencia válida.

14 Protocolo de evaluación y evidencia empírica

La evaluación seguirá un protocolo documentado con casos de referencia y mediciones repetibles; los resultados no se anticiparán ni sustituirán con ejemplos fabricados.

Tabla 11. Diseño preliminar de la evaluación

Componente	Prueba y métrica
RAG y producto	Al menos 20 casos con evidencia esperada; acierto@k, fidelidad, relevancia 0–5 y comparación con/sin RAG.
Comparación científica	Etiquetas manuales para pares comparables, no comparables y divergentes; matriz de confusión y falsos positivos.
Guardrails	10 entradas problemáticas y 10 normales; bloqueos correctos y falsos positivos.
Caché	Consultas idénticas y paráfrasis; tasa de hit, latencia y errores de reutilización semántica.
Enrutamiento	Casos etiquetados por complejidad; ruta correcta y tiempo por modelo.
Agente	Casos con recuperación pobre; mejora posterior a reformular e iteraciones promedio.
Observabilidad	Latencia total y por capa, media y máxima; trazas con comentarios de usuarios.

14.1 Evaluación científica de comparaciones

El conjunto de referencia se construirá seleccionando pasajes del corpus y registrando para cada uno afirmación, variables, campos ausentes y texto de sustento. La relación entre pares será revisada manualmente con reglas escritas antes de ejecutar el sistema. Los desacuerdos entre anotaciones deberán resolverse por revisión explícita y quedar en el protocolo; no se describirá un resultado del LLM como verdad de referencia.

Se medirán precisión, exhaustividad y F1 de extracción de campos y de clasificaciones, además de tasa de abstención apropiada, proporción de citas existentes y precisión de alertas de divergencia. Para recuperación se medirá Recall@k o Hit@k con preguntas cuya evidencia de referencia esté identificada; se contrastarán dos embeddings bajo las mismas consultas y el mismo conjunto de documentos. Para los dos modelos de generación se revisarán validez JSON, corrección contextual,

citas, latencia y memoria. No existen aquí datos medidos: los valores se incorporarán en el informe experimental una vez ejecutadas las pruebas.

14.2 Criterios de aceptación del producto

Tabla 12. Escenarios que deberán verificarse con pruebas funcionales

Caso de aceptación	Comportamiento requerido
Documento autorizado	Se registra licencia, metadatos y estado; es posible rastrear todos sus fragmentos a un archivo.
Documento no extraíble	El sistema advierte la pérdida de información y no presenta inferencias como texto recuperado.
Afirmación sin sustento	La verificación de salida la rechaza o la marca sin evidencia; no la incluye como hallazgo validado.
Unidades incompatibles	El par se marca como no comparable hasta que exista conversión válida y contexto suficiente.
Indicio de divergencia	Se presentan ambas citas, condiciones y razones; la clasificación permanece revisable.
Cambio de corpus	Se genera nueva versión y se invalida caché dependiente de la versión anterior.
Falla de Ollama	La API registra traza, aplica timeout/alternativa configurada y responde sin inventar resultados.
Informe exportado	Incluye selección de corpus, fecha, configuraciones, matriz, DOI, estado de revisión y limitaciones.

15 Requisitos funcionales del producto

La siguiente especificación establece obligaciones observables para el diseño y las pruebas. Los identificadores son referencias de ingeniería, independientes de la evaluación docente. La prioridad P0 representa el núcleo del producto; P1 amplía la experiencia y la auditabilidad una vez estabilizado ese núcleo.

Tabla 13. Catálogo de requisitos funcionales verificables

ID	Prioridad	Requisito funcional y condición observable
RF01	P0	Crear un proyecto de revisión con dominio, objetivo, filtros y versión.
RF02	P0	Importar PDF y registrar origen, licencia, DOI, título y estado de extracción.
RF03	P0	Conservar fragmentos con doc_id, página/sección y versión de documento.
RF04	P0	Crear embeddings persistentes y recuperar pasajes relevantes con filtros.
RF05	P0	Extraer afirmaciones tipadas en JSON con campos ausentes explícitos.
RF06	P0	Comparar afirmaciones considerando variables y condiciones experimentales.
RF07	P0	Rechazar afirmaciones sin fuente válida;

ID	Prioridad	Requisito funcional y condición observable
		comunicar abstención.
RF08	P0	Exponer API REST documentada y consumirla desde cliente web.
RF09	P0	Ejecutar guardrails, caché, enrutamiento, agente y observabilidad.
RF10	P0	Exportar matriz e informe PDF con referencias y estados de revisión.
RF11	P1	Revisar, corregir y desestimar afirmaciones conservando historial.
RF12	P1	Filtrar comparaciones por documento, variable, método y estado.
RF13	P1	Registrar feedback vinculado a análisis, traza y versión.
RF14	P1	Visualizar indicadores técnicos y emitir bitácora reproducible.

16 Requisitos no funcionales y atributos de calidad

Los atributos se diseñan como compromisos medibles; los umbrales numéricos definitivos se establecerán tras una medición de línea base sobre el equipo de 16 GB de RAM. No sería riguroso prometer una latencia universal sin conocer tamaño real del corpus, longitud de contexto y modelos instalados.

Tabla 14. Atributos de calidad y método de comprobación

Atributo	Criterio de ingeniería y forma de verificación
Trazabilidad	El 100 % de afirmaciones visibles como respaldadas debe referir a un fragmento persistente y a un documento; prueba automatizada de integridad referencial.
Fiabilidad de salida	Toda respuesta científica se valida contra esquema y fuentes; las fallas originan error o abstención, no una conclusión aparente.
Reproducibilidad	Cada análisis conserva versión de corpus, indexación, modelos, prompts, parámetros y huella de configuración.
Seguridad documental	Validación de tipo/tamaño y permisos; documentos tratados como datos no confiables; no ejecutar instrucciones del PDF.
Disponibilidad local	Frontend, backend, base vectorial y modelos funcionan sin proveedor de inferencia externo; prueba con red desconectada.
Desempeño	Registrar mediana, p95, memoria y tasa de error por etapa con tamaño de corpus y configuración reportados.
Modificabilidad	El reemplazo de un adaptador de modelos o vectores no exige cambios a los esquemas de dominio; prueba de sustitución.
Usabilidad	Las tareas importar, generar matriz, revisar fuente y exportar cuentan con estados y mensajes claros; prueba guiada.
Auditabilidad	Cada análisis y corrección posee trace_id, fecha y cambio de

Atributo	Criterio de ingeniería y forma de verificación
	estado; los logs excluyen información sensible innecesaria.

17 Límites científicos y política de clasificación

MatriScope distinguirá cinco resultados interpretativos: (a) compatible, cuando los registros comparables expresen conclusiones concordantes; (b) divergencia potencial, cuando bajo condiciones suficientemente próximas se observen direcciones o magnitudes discrepantes que requieren revisión; (c) no comparable, cuando material, proceso, método, unidad o contexto impidan cotejar; (d) evidencia insuficiente, cuando falten pasajes o metadatos para resolver la relación; y (e) no evaluado, cuando el análisis haya fallado o no exista aún revisión. Estas etiquetas son reglas del producto por validar, no hechos científicos sobre publicaciones específicas.

La comparación se hará en dos fases. Primero, un filtro estructural exigirá compatibilidad de material y pertinencia de proceso/variable, e identificará diferencias de método y unidades. Después, el modelo propondrá una explicación sustentada en los fragmentos recuperados. Solo podrá emitirse una divergencia potencial si el sistema exhibe ambas afirmaciones, sus campos de control y la justificación; no bastará una distancia semántica alta, palabras como “contradice” ni una puntuación numérica del modelo.

El sistema no sustituirá ensayos físicos, revisión por pares ni juicio experto. No calculará propiedades de una pieza real a partir del texto; no distinguirá automáticamente defectos en micrografías; no realizará metaanálisis estadístico cuando los estudios reporten variables heterogéneas; no generalizará resultados a materiales ajenos al corpus. Ante una tabla, imagen o fórmula ilegible, mostrará el límite de extracción y pedirá revisión de fuente.

18 Gestión de riesgos, seguridad y uso responsable

- Alucinaciones o citas erróneas: contrastar IDs de fuentes y rechazar afirmaciones no verificables.
- Falsas contradicciones: conservar material, método, condiciones y unidades; incluir categoría “no comparable”.
- PDF escaneado o tablas complejas: dejar constancia de información no extraída, sin deducir valores ausentes.
- Licencias y datos sensibles: seleccionar documentos permitidos, registrar autorizaciones y anonimizar datos.
- Costo computacional: ejecutar modelos de manera secuencial y medir RAM, latencia y tamaño real.
- Inyección de instrucciones: separar instrucciones de sistema de contenido documental; tratar el PDF como entrada no confiable; validar salidas y operaciones autorizadas.
- Uso académico de IA: declarar el apoyo recibido, registrar revisión humana y advertir que el sistema produce resultados revisables.

OWASP (2025) identifica la inyección de prompts y debilidades relacionadas con vectores/embeddings como riesgos de aplicaciones basadas en LLM. Un RAG no constituye por sí mismo un mecanismo de seguridad; se requieren políticas explícitas ante instrucciones maliciosas incrustadas en textos, cambios de fuentes, fallas de servicios y respuestas sin sustento. La función de guardrails verificará, como mínimo, extensión/tamaño y patrones sospechosos de entrada; en salida verificará conformidad de esquema y existencia de citas. El informe técnico posterior registrará fallos y falsos bloqueos durante pruebas.

19 Entregables, documentación y evolución

El producto software estará compuesto por código fuente del frontend y servicio API, procedimiento reproducible de instalación local, corpus autorizado con manifiesto bibliográfico, scripts de ingesta, índices regenerables, conjuntos de prueba y resultados medidos. El artefacto científico de usuario será el mapa de evidencia y su informe PDF con trazabilidad. La documentación de ingeniería incluirá vistas de contexto, contenedores, capas, componentes y despliegue; secuencias de ingesta, consulta, caché, bloqueo por guardrails y ciclo del agente; además de decisiones de arquitectura (ADR) que registren contexto, alternativas, decisión y consecuencias.

Se reservará el informe técnico de resultados para documentar la implementación real, experimentos, pruebas, incidencias y diferencias respecto de esta propuesta. Así se evita confundir una especificación de diseño con una demostración de funcionamiento. Las versiones del informe identificarán la versión de la aplicación y del corpus utilizado.

20 Plan de ejecución y control de cambios

Tabla 15. Secuencia lógica de desarrollo propuesta

Fecha	Actividad prevista
Fase I	Delimitar corpus, licencias, historias de usuario, modelo de datos y contratos de servicio.
Fase II	Implementar ingesta, extracción, embeddings e índice; crear pruebas de recuperación.
Fase III	Incorporar orquestación, guardrails, router, gateway, caché y comparación contextual.
Fase IV	Integrar interfaz web, revisión de fuentes, matriz exportable, observabilidad y feedback.
Fase V	Ejecutar experimentos, revisar errores y producir documentación técnica reproducible.

Cada fase quedará terminada únicamente cuando exista código ejecutable, pruebas asociadas y evidencia de funcionamiento. La fecha académica establecida para la presentación deberá gobernar la planificación operativa sin reducir el rigor de la definición funcional. Un cambio de alcance —por ejemplo, incorporar imágenes, nuevos materiales o múltiples perfiles autenticados— requerirá una decisión documentada y nuevos casos de evaluación.

21 Diseño integral del producto: identidad, navegación y especificación de pantallas

Esta ampliación establece el diseño de producto como un contrato de experiencia de usuario conectado a los casos de uso, componentes y evidencias técnicas exigidos en la asignatura. Se incorporan capturas completas de las once vistas de trabajo; cada figura incluye la navegación lateral y el área central, sin recortes. Las pantallas muestran estados conceptuales y funcionalidad limitada de interfaz: todavía no representan resultados científicos obtenidos por modelos o por una base vectorial operativa.

21.1 Identidad gráfica de MatriScope

El identificador MatriScope se utiliza como marca del sistema. Su tratamiento visual adopta una estética de laboratorio digital: tipografía sobria, fondo claro, navegación estable, acentos azul profundo y verde azulado para distinguir acciones, estados y evidencias. Los colores son parte de la propuesta gráfica; no representan una afiliación institucional ni certificaciones externas.



Figura 4. Propuesta de identidad visual del producto MatriScope.

Regla de diseño: cada módulo conservará encabezado con título y propósito, menú lateral con grupos «Espacio de trabajo», «Análisis científico» y «Plataforma», controles identificables y mensajes diferenciados para estados vacío, pendiente, validado y error. Para escritorio, el contenido crecerá verticalmente sin cortar las opciones del menú; para anchos reducidos se ofrecerá navegación colapsable y desplazamiento accesible.

21.2 Inicio y síntesis del espacio de trabajo

Finalidad. Ofrecer un punto de entrada claro al ciclo científico, al proyecto activo y a las tareas pendientes, sin confundir los indicadores simulados con métricas ejecutadas.

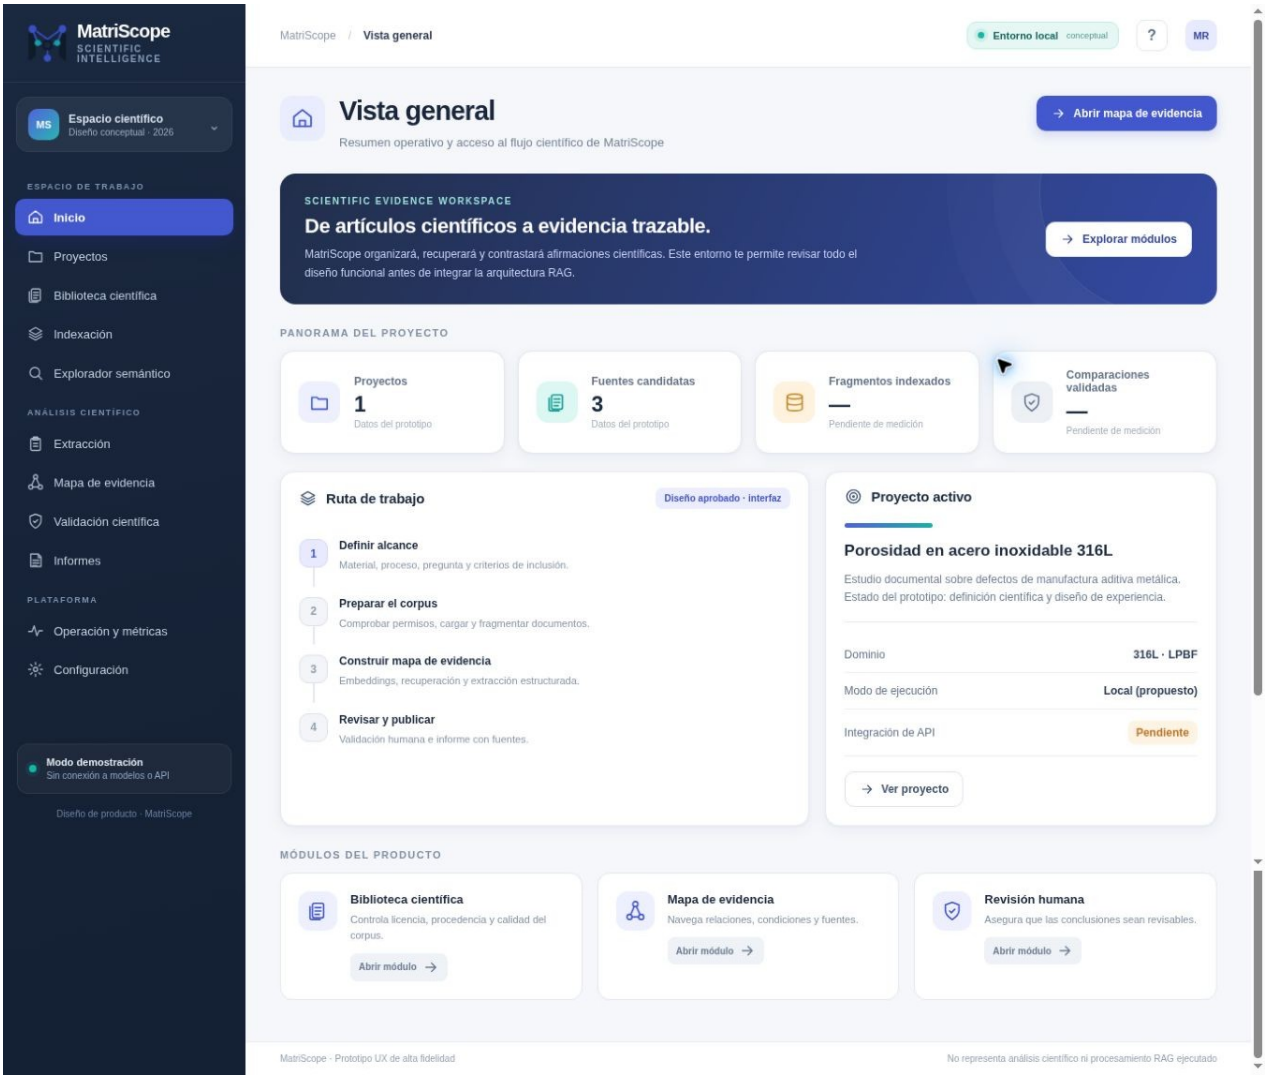


Figura 5. Vista completa del módulo «Inicio y síntesis del espacio de trabajo»; diseño conceptual de interfaz.

Entradas. Proyecto seleccionado, resumen de corpus, trabajos de indexación y análisis autorizados; todas las cifras deben proceder de la API.

Operación funcional. Consultar estados consolidados del proyecto y mostrar acciones contextuales: preparar biblioteca, iniciar indexación, revisar evidencia o abrir un informe.

Resultado verificable. Panel de estado y accesos al flujo; avisos cuando no existan documentos, índices o análisis válidos.

Implementación prevista. Web → GET /proyectos y GET /metricas → C1/API y C7/almacenes; T1 registra solicitudes. No se mostrarán estadísticas ficticias.

21.3 Proyectos de investigación

Finalidad. Delimitar una revisión: pregunta científica, material, proceso, tipo de defecto, criterios de inclusión y responsables de revisión.

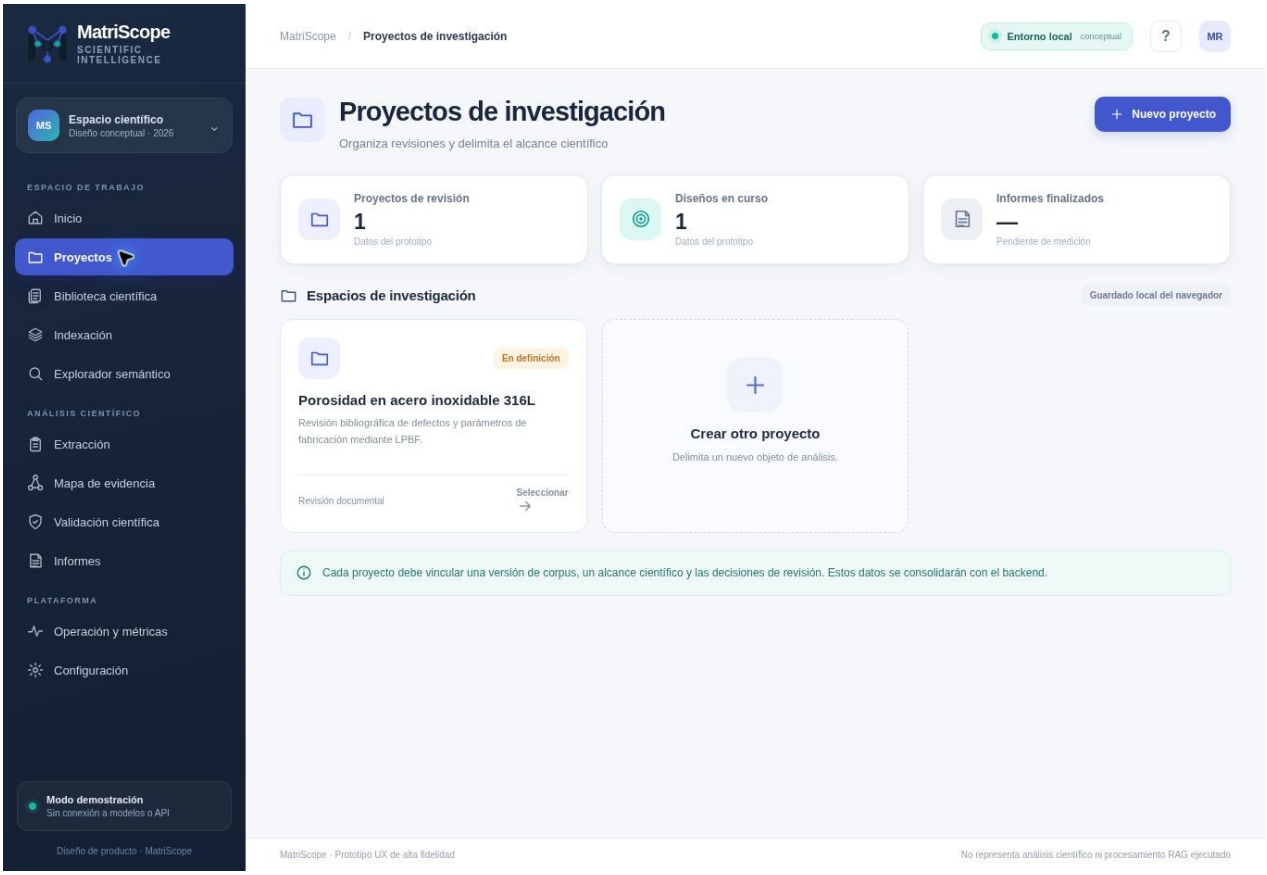


Figura 6. Vista completa del módulo «Proyectos de investigación»; diseño conceptual de interfaz.

Entradas. Nombre, descripción, pregunta, filtros 316L/LPBF/porosidad, versión del corpus y política de selección bibliográfica.

Operación funcional. Crear, seleccionar y versionar espacios de trabajo; impedir mezclar evidencia de proyectos distintos y dejar trazabilidad de sus cambios.

Resultado verificable. Identificador de proyecto, estado de preparación, configuración asociada e historial de revisiones.

Implementación prevista. Web → POST/GET /proyectos → C1, C2, C7; T1 registra cambios. En el prototipo la creación solo se guarda en el navegador.

21.4 Biblioteca científica

Finalidad. Controlar un inventario documental autorizado y comprobable, base de toda afirmación emitida por el sistema.

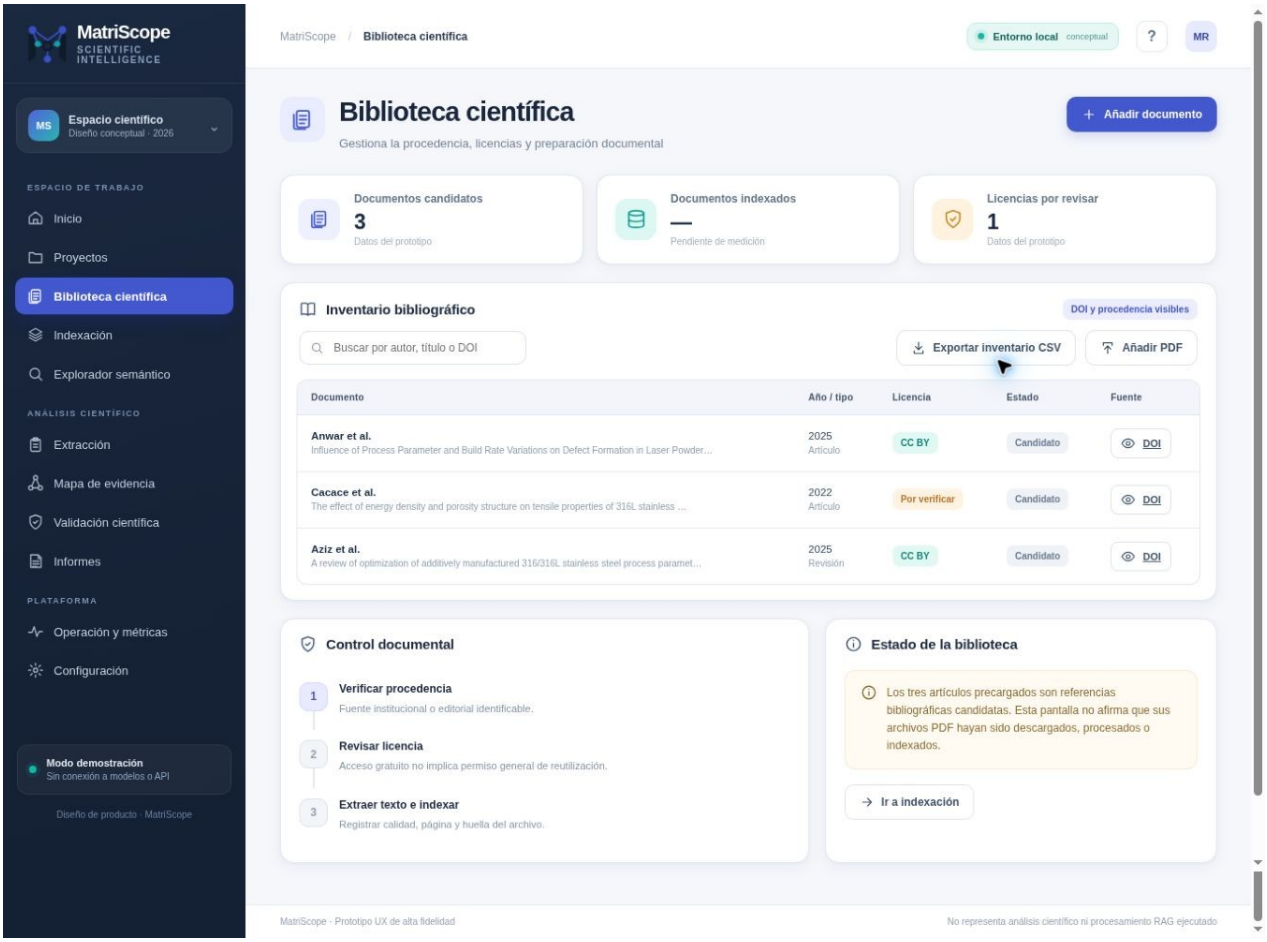


Figura 7. Vista completa del módulo «Biblioteca científica»; diseño conceptual de interfaz.

Entradas. Archivos PDF y, como ampliación posterior, otros formatos; DOI, autores, año, licencia, fuente y proyecto.

Operación funcional. Verificar formato y derechos de uso, calcular huella digital del archivo, registrar metadatos, controlar duplicados y estado de autorización.

Resultado verificable. Catálogo de documentos con identificador, procedencia, versión y estado; bloqueo de indexación si falta autorización.

Implementación prevista. Web → POST/GET/DELETE /documentos → C1, C3, C7; borrar implica desindexar e invalidar C4. La maqueta solo registra nombres.

21.5 Indexación y embeddings

Finalidad. Convertir documentos autorizados en fragmentos recuperables, con página y metadatos suficientes para auditoría bibliográfica.

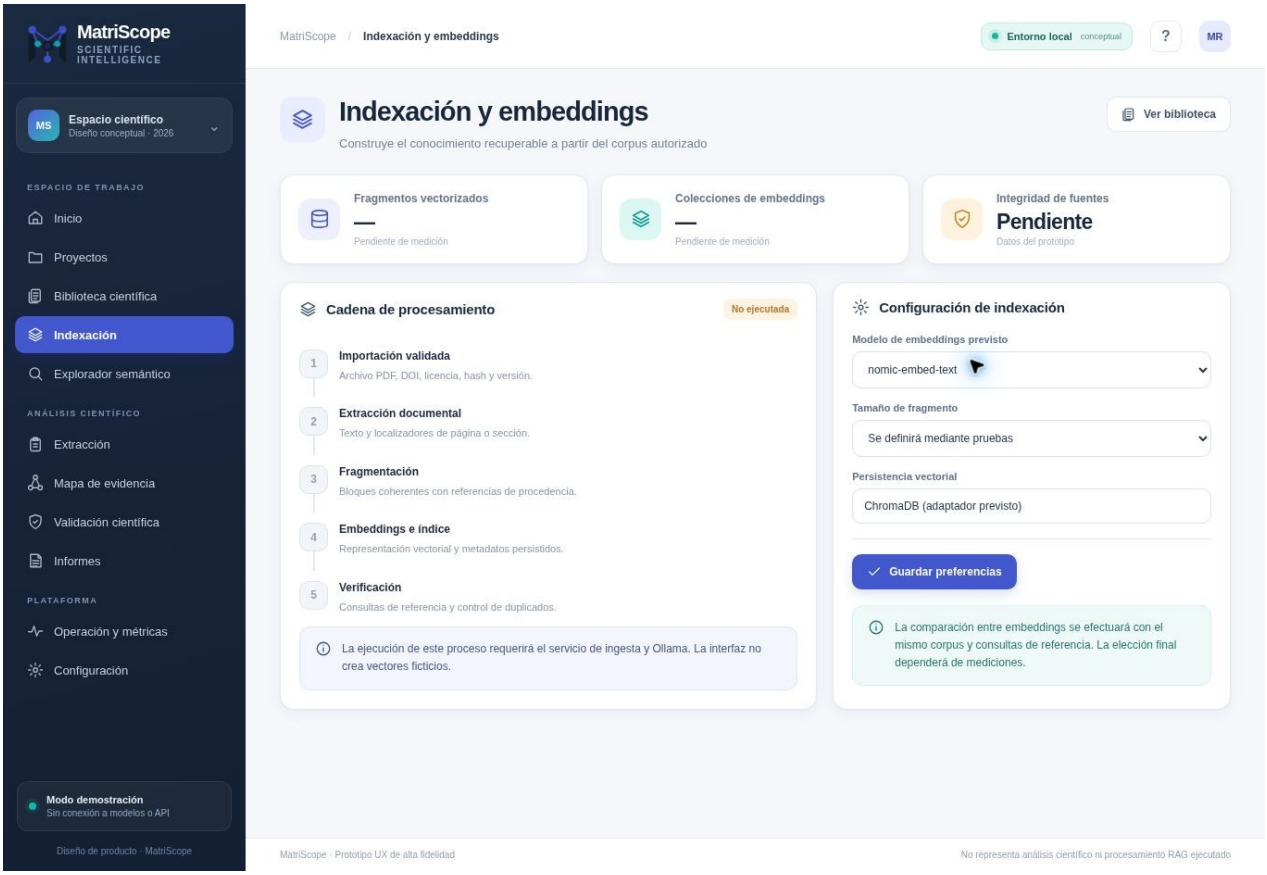


Figura 8. Vista completa del módulo «Indexación y embeddings»; diseño conceptual de interfaz.

Entradas. Documentos validados, estrategia de extracción textual, tamaño y solapamiento de fragmentos, modelo de embeddings seleccionado.

Operación funcional. Extraer texto, preservar páginas y secciones, fragmentar, generar vectores, persistirlos e invalidar la caché ante un cambio documental.

Resultado verificable. Índice vectorial versionado, registro de fragmentos, documentos con errores de extracción y trazas de procesamiento.

Implementación prevista. POST /documentos o POST /indexaciones → C1, C2, C5, C7 y T1; C4 invalida entradas dependientes del corpus.

21.6 Explorador semántico

Finalidad. Localizar pasajes relevantes por significado, no solo por coincidencia de palabras, antes de elaborar una comparación.

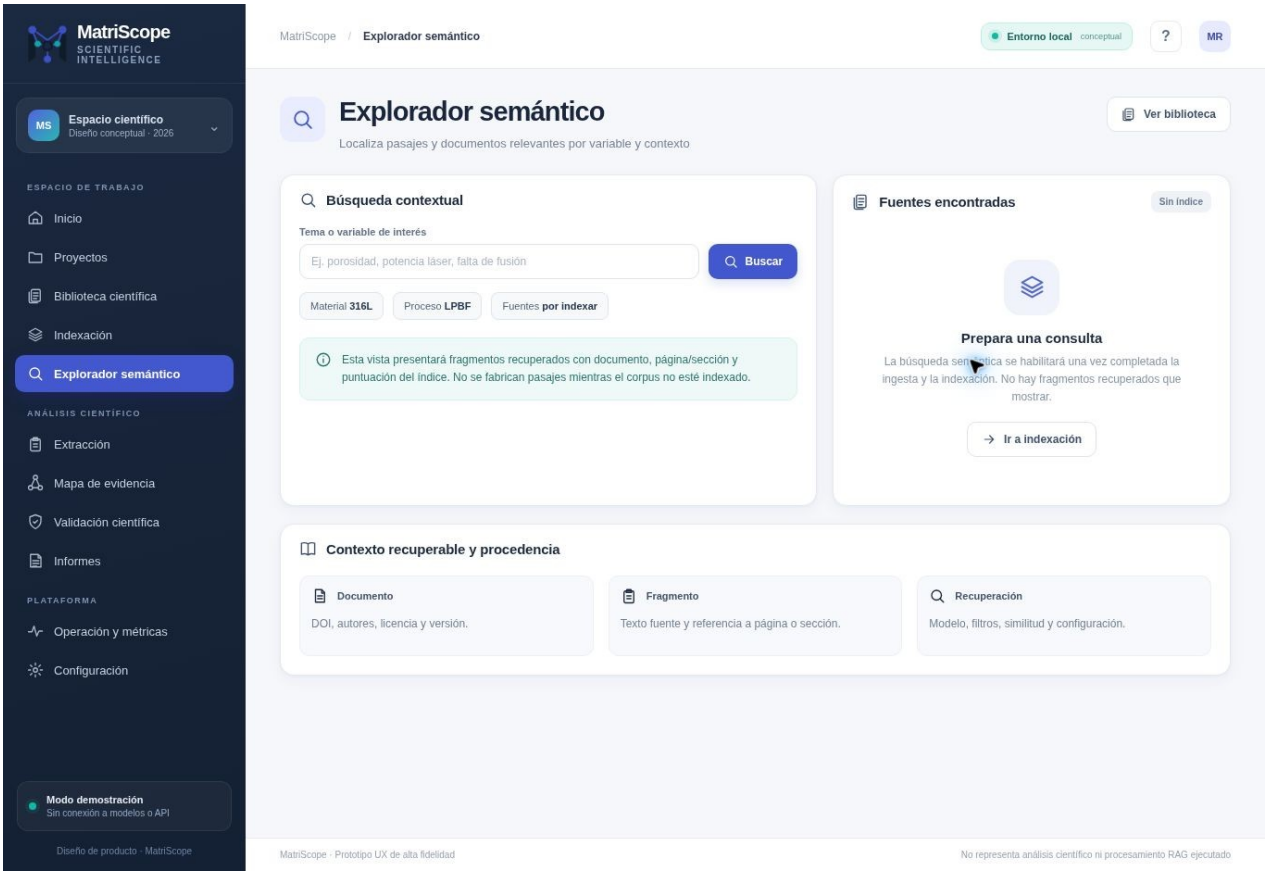


Figura 9. Vista completa del módulo «Explorador semántico»; diseño conceptual de interfaz.

Entradas. Pregunta o variables científicas, proyecto, filtros documentales, top-k y umbral de similitud calibrado.

Operación funcional. Aplicar guardrails, comprobar caché, recuperar fragmentos por embeddings y construir contexto restringido a fuentes identificables.

Resultado verificable. Fragmentos con documento, sección/página, puntuación de recuperación y vínculo a la fuente; abstención ante evidencia insuficiente.

Implementación prevista. POST /consultas → C1–C7; T1 traza el camino y T2 permite calificar pertinencia. La vista actual no realiza búsqueda vectorial.

21.7 Extracción de afirmaciones científicas

Finalidad. Transformar evidencia dispersa en registros estructurados que el investigador pueda revisar y comparar.

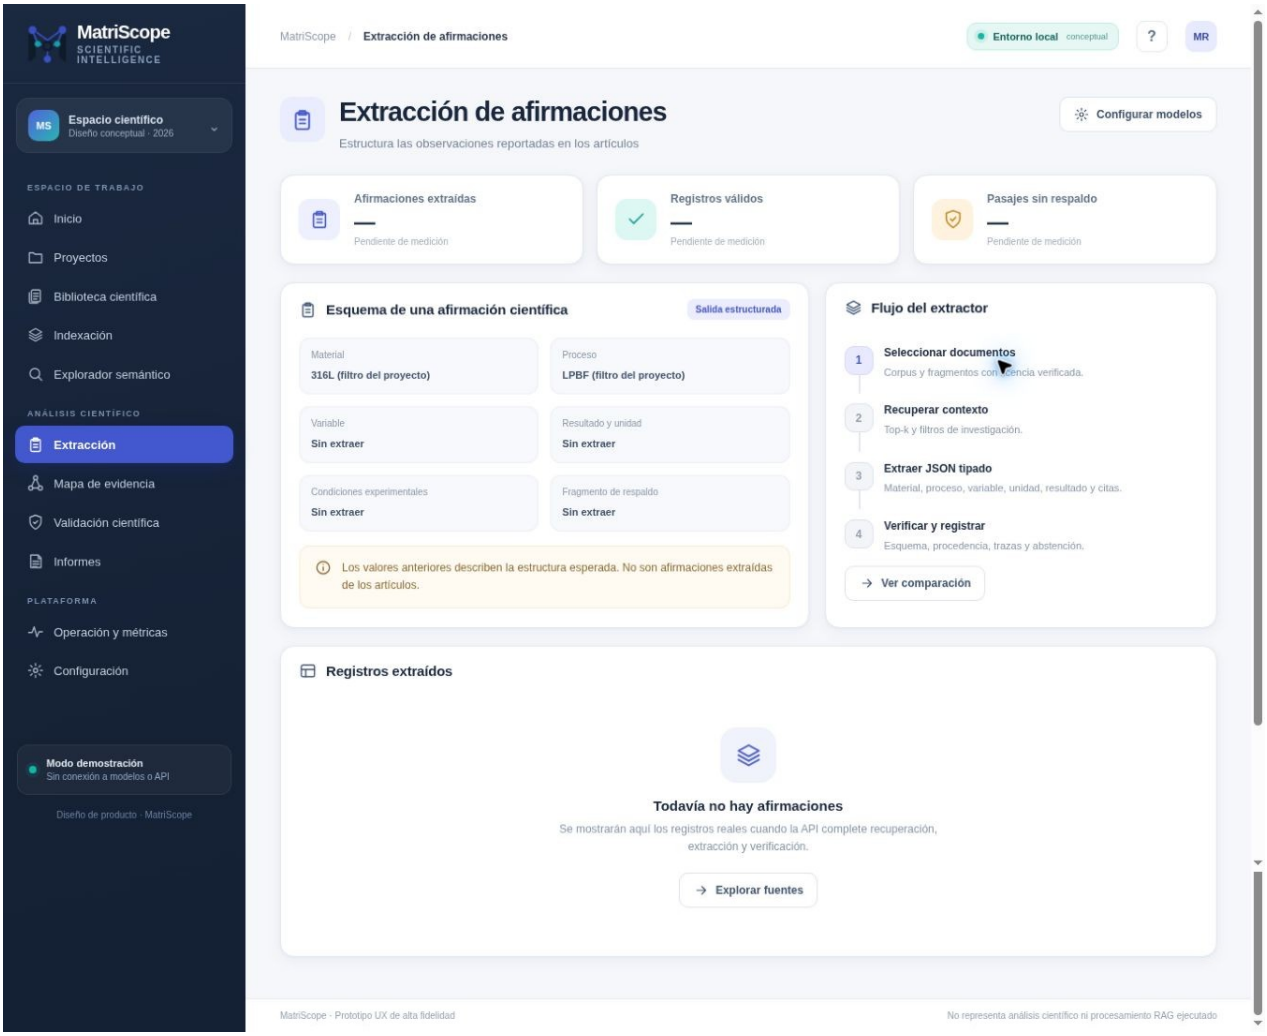


Figura 10. Vista completa del módulo «Extracción de afirmaciones científicas»; diseño conceptual de interfaz.

Entradas. Fragmentos recuperados y reglas de extracción: aleación, proceso, parámetros, defecto, método de medición, resultado y unidades.

Operación funcional. Solicitar extracción con formato tipado, comprobar esquema y consistencia de unidades y exigir cita verificable por campo.

Resultado verificable. Fichas de afirmaciones con valor literal, contexto experimental, fuente, confianza operativa y estado pendiente de revisión.

Implementación prevista. POST /extracciones → C2, C3 de salida, C5, C6 y C7; no validar por interfaz afirmaciones creadas artificialmente.

21.8 Mapa de evidencia científica

Finalidad. Entregar el resultado principal del producto: una matriz y una representación navegable de relaciones entre estudios y observaciones.

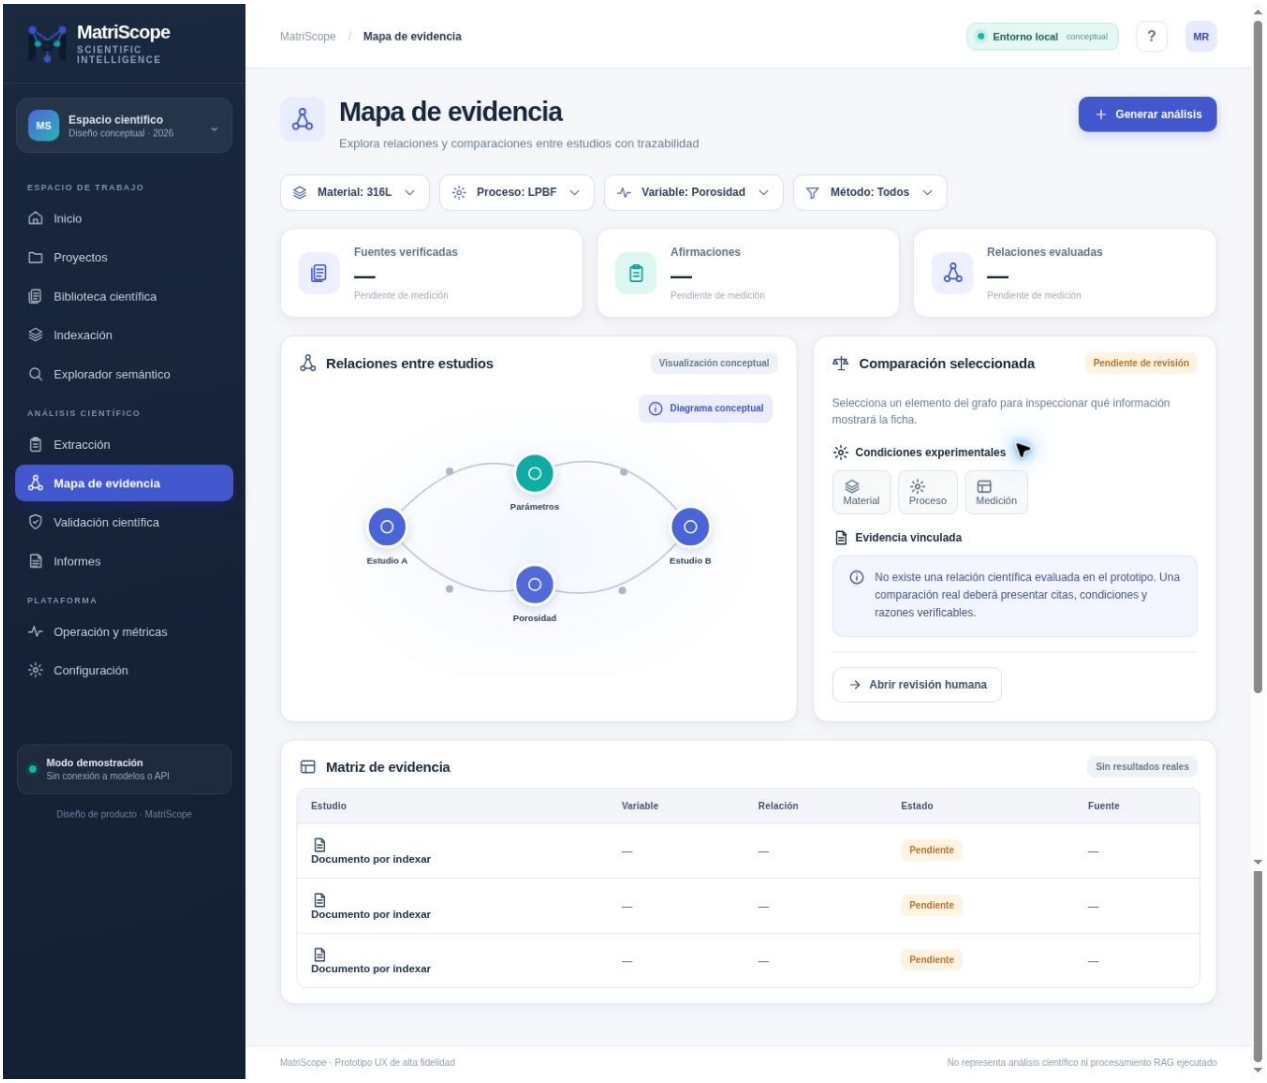


Figura 11. Vista completa del módulo «Mapa de evidencia científica»; diseño conceptual de interfaz.

Entradas. Afirmaciones trazables, condiciones de ensayo, variables, filtros, criterios de comparabilidad y estado de revisión humana.

Operación funcional. Agrupar por contexto científico, vincular estudios y resultados, distinguir compatibilidad, divergencia aparente e información no comparable.

Resultado verificable. Mapa/matriz exportable, relaciones con referencias exactas, justificación de comparaciones y advertencias de incertidumbre.

Implementación prevista. POST /mapa-evidencia → C1–C7; T1 recoge ruta de ejecución. El grafo mostrado en la maqueta es ilustrativo, no un hallazgo.

21.9 Validación y dictamen científico

Finalidad. Mantener a la investigadora como responsable de aceptar, corregir o rechazar afirmaciones propuestas por la IA.

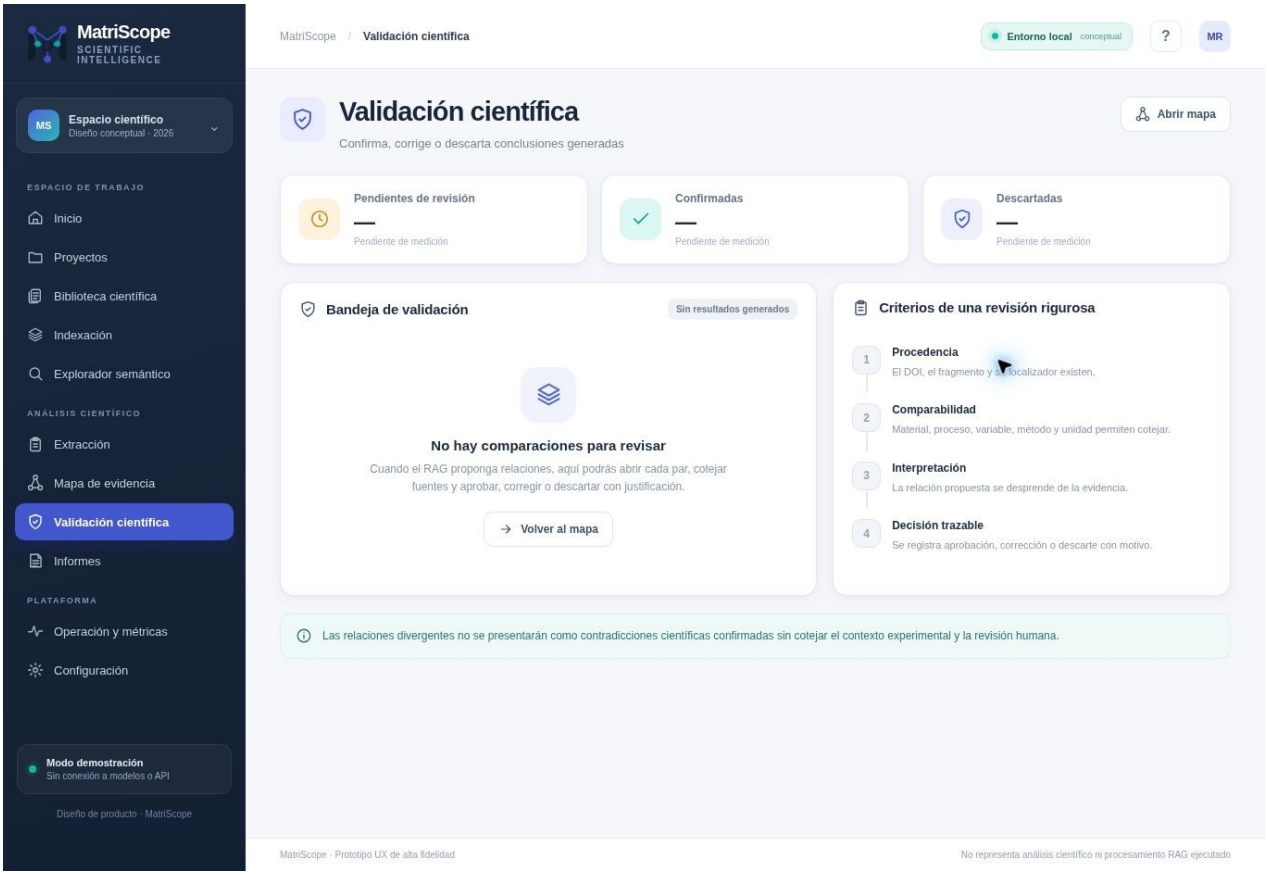


Figura 12. Vista completa del módulo «Validación y dictamen científico»; diseño conceptual de interfaz.

Entradas. Ficha de afirmación, documento y página original, contexto recuperado y motivo de la decisión de revisión.

Operación funcional. Abrir evidencia primaria, contrastar con el pasaje, registrar veredicto, anotación y fecha; conservar historial sin sobrescritura silenciosa.

Resultado verificable. Registro auditable de validación y conjunto de afirmaciones publicables; las rechazadas se excluyen de resultados definitivos.

Implementación prevista. POST /validaciones y POST /retroalimentacion → C1, C2, C7 y T2, con traza T1; se implementarán controles de salida C3.

21.10 Informes y exportación

Finalidad. Formalizar los hallazgos revisados como un producto documental reproducible, sin sustituir la lectura crítica de los originales.

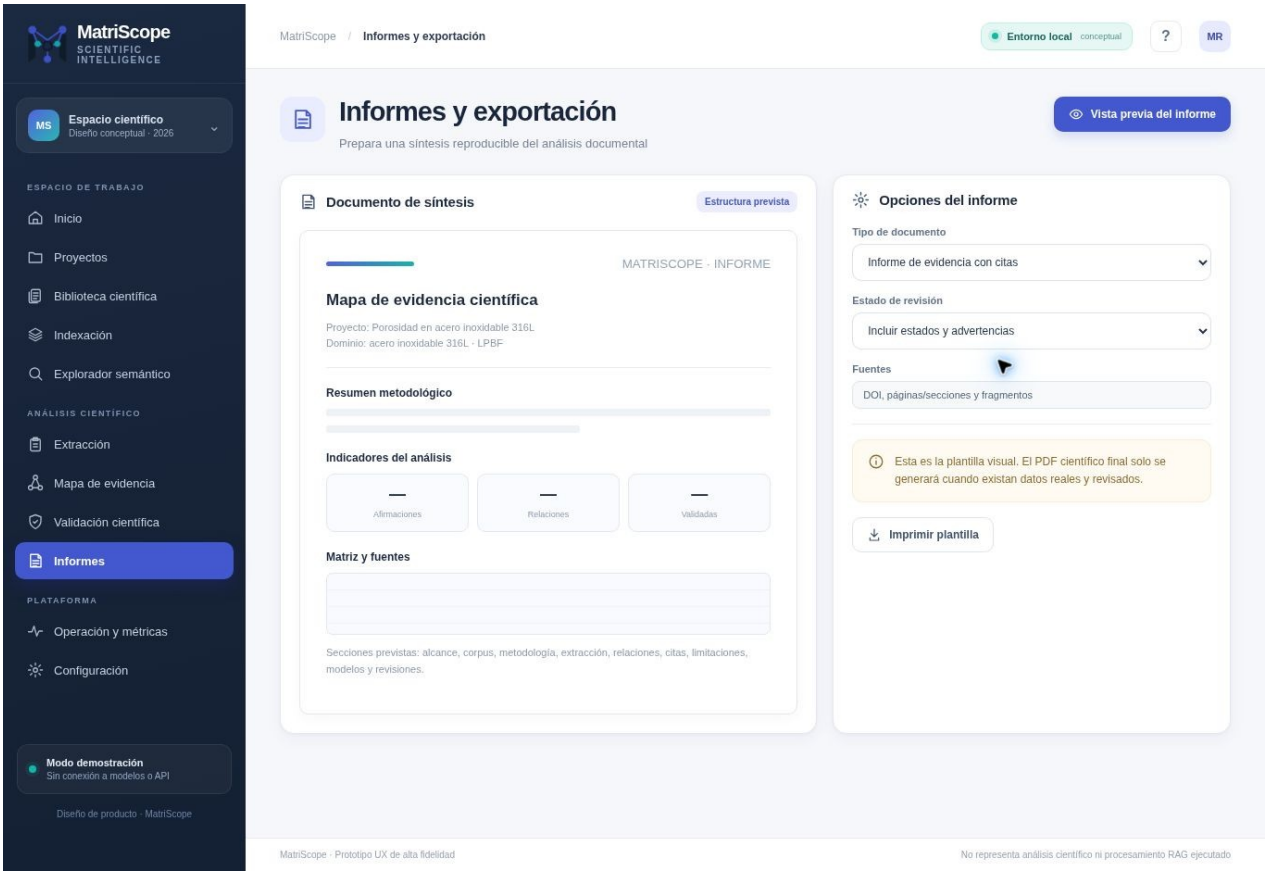


Figura 13. Vista completa del módulo «Informes y exportación»; diseño conceptual de interfaz.

Entradas. Proyecto, corpus/versiones, criterios de comparación, evidencia confirmada y configuración del experimento RAG.

Operación funcional. Componer resumen, metodología, matriz, fichas, referencias, limitaciones y bitácora de validación; comprobar integridad de citas.

Resultado verificable. Informe PDF fechado, identificador de versión y anexos de trazabilidad; exportación prohibida si faltan fuentes esenciales.

Implementación prevista. GET /informes/{id} y generación de documento en C2/C7; verificaciones C3 y telemetría T1. Hoy solo existe una plantilla visual.

21.11 Operación, métricas y seguimiento

Finalidad. Exponer el comportamiento real de la arquitectura para diagnosticar fallas y demostrar funcionamiento por capa.

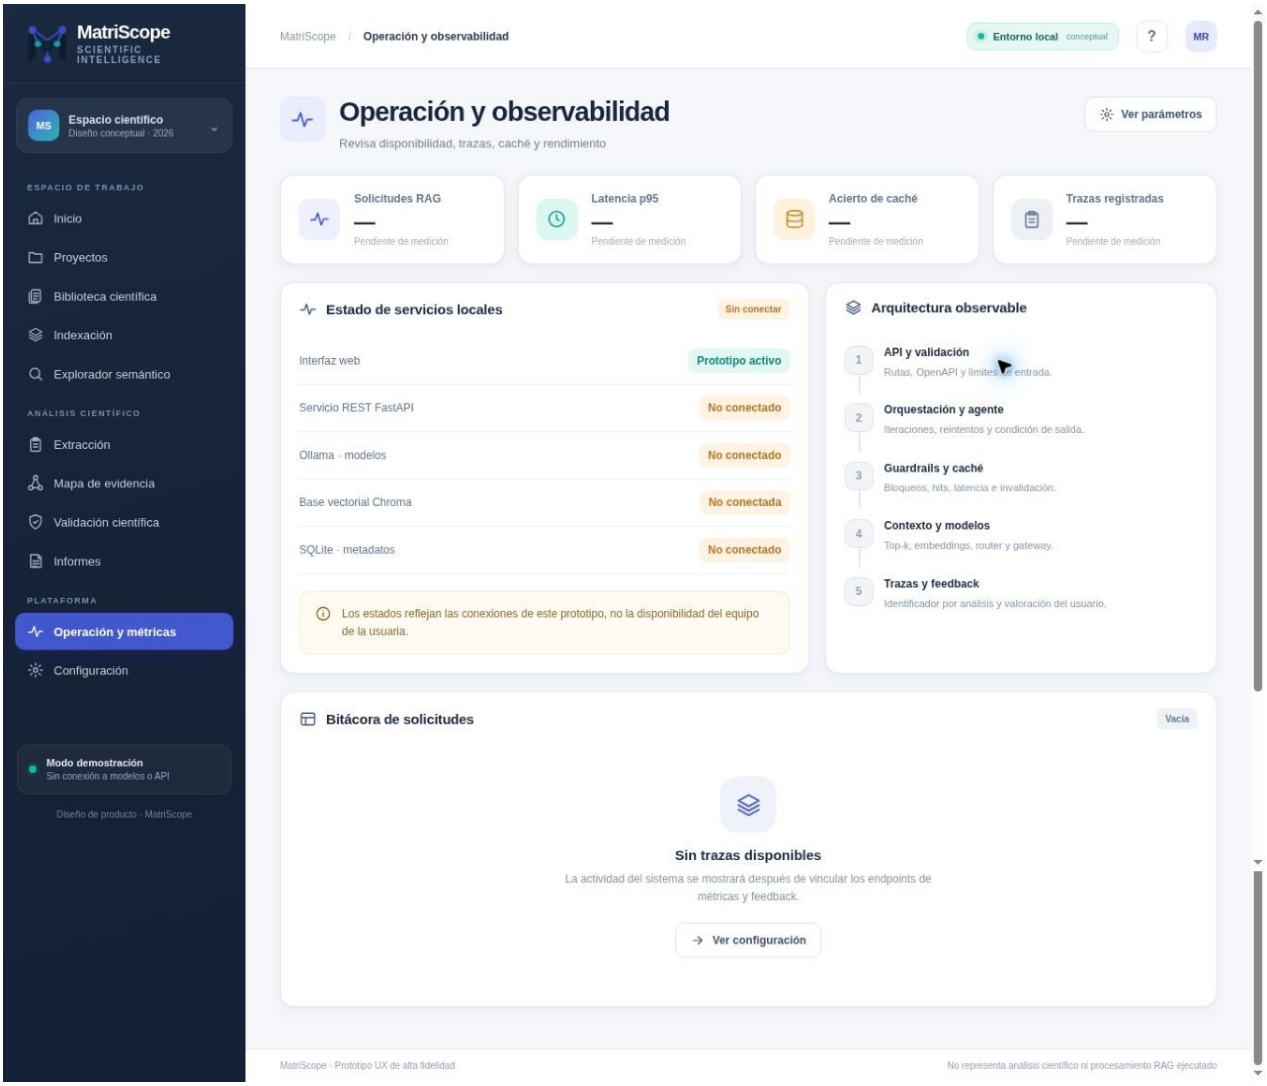


Figura 14. Vista completa del módulo «Operación, métricas y seguimiento»; diseño conceptual de interfaz.

Entradas. Trazas, latencia por etapa, ruta de modelo, resultados de caché, guardrails, excepciones y retroalimentación.

Operación funcional. Agrupar por consulta y versión de experimento; calcular métricas a partir de registros reales, sin muestras precargadas presentadas como medidas.

Resultado verificable. Panel y endpoint con métricas de latencia, caché, seguridad, selección de modelo y satisfacción del usuario.

Implementación prevista. GET /metricas y GET /health → T1, C1, C4, C6, C7; T2 registra opinión unida al trace_id.

21.12 Configuración técnica y ejecución local

Finalidad. Controlar los parámetros cuya variación cambia los resultados y respaldar la comparación experimental de alternativas.

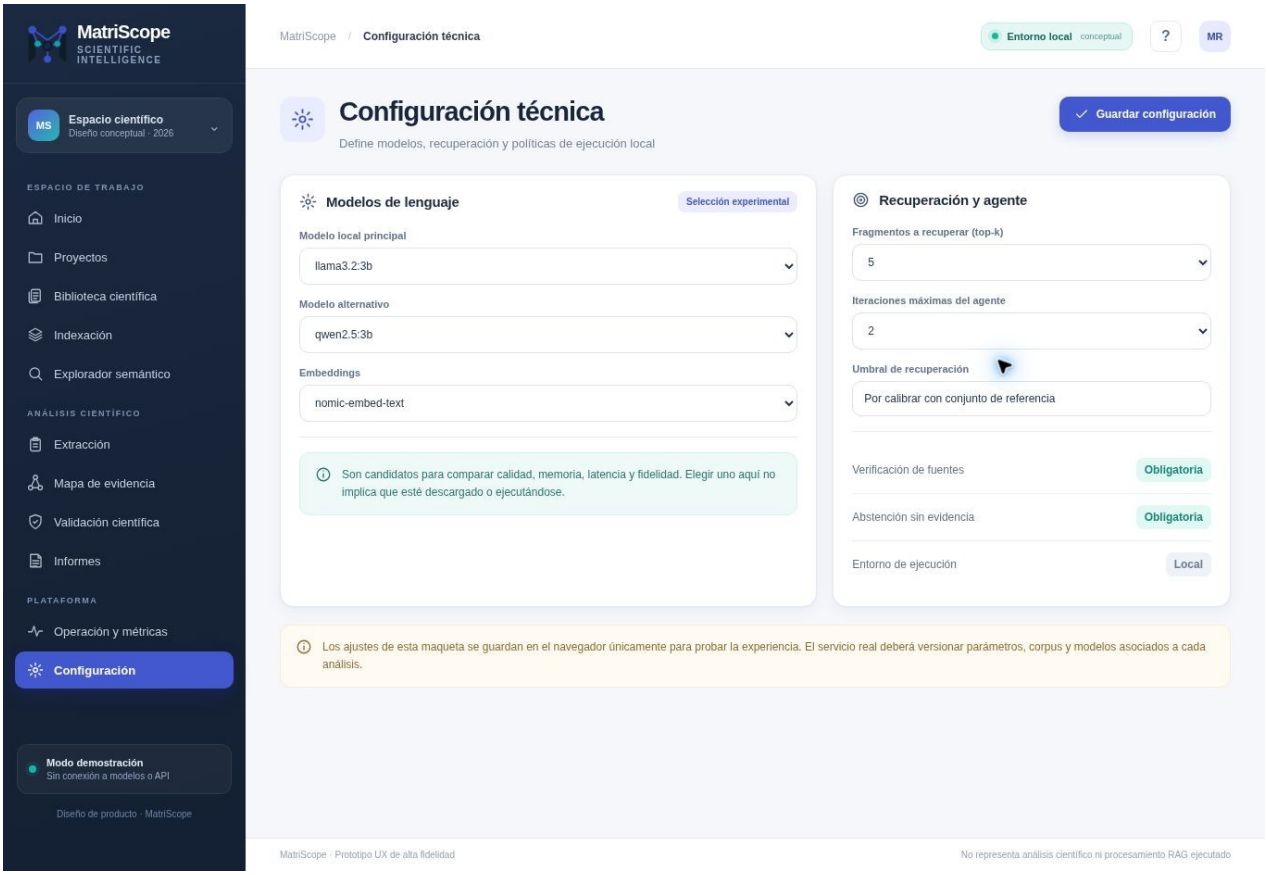


Figura 15. Vista completa del módulo «Configuración técnica y ejecución local»; diseño conceptual de interfaz.

Entradas. Dos o más modelos de lenguaje candidatos, dos o más modelos de embeddings, top-k, umbrales, máximos de iteraciones y tiempos límite.

Operación funcional. Validar disponibilidad local, versionar configuración, probar ruteo/alternativas, guardar ADR asociados y evitar cambios tácitos durante una corrida.

Resultado verificable. Perfil reproducible de ejecución con modelos activos y respaldo, criterios documentados y estado de servicios.

Implementación prevista. GET /configuracion y configuración administrada por C6/C7; decisiones de C2/C3/C4/C5/T1. Los selectores actuales no descargan modelos.

22 Correspondencia del producto con los requisitos oficiales

La tabla siguiente corresponde a «Proyecto integrador: producto inteligente en capas con modelos de lenguaje, embeddings y RAG» (2026, secciones 3–11) y a su rúbrica de evaluación (2026, requisitos obligatorios y criterios analíticos). Indica diseño, ubicación de implementación y prueba necesaria; no constituye una declaración de cumplimiento actual. Se omiten deliberadamente las ponderaciones de evaluación.

Estado al 6 de noviembre de 2026: el artefacto web local es un prototipo de navegación con datos de ejemplo. Los modelos, la API REST, el índice vectorial, la inferencia, el RAG, las métricas y los experimentos no están integrados en ese prototipo. Su realización se especifica a continuación como trabajo pendiente y se verificará con evidencia reproducible.

Código / exigencia	Dónde se materializa en MatriScope	Evidencia objetiva para acreditar implementación
R1 · Dominio y corpus	Proyectos + Biblioteca: alcance 316L, LPBF y porosidad; origen, derechos y versión documental.	Inventario con archivos autorizados, licencias, procedencia y pregunta científica definida.
R2 · Ejecución local	Configuración + despliegue: web, API, Ollama, almacenamiento de documentos, caché y base vectorial locales.	Demostración sin usar APIs de modelos externas; capturas de procesos/puertos y prueba sin conexión.
R3 · Comparación de modelos	Configuración + evaluación: ≥2 LLM y ≥2 embeddings medidos con el mismo corpus.	Scripts, condiciones de hardware, tabla de exactitud/acierto@k/latencia/memoria y decisión argumentada.
R4 · Embeddings	Biblioteca → Indexación → C5/C7.	Embeddings persistidos y recuperables en base vectorial; metadatos y endpoint operativos.
R5 · RAG con fuentes	Explorador + Extracción + Mapa → C5/C6.	Salida generada solo a partir de fragmentos recuperados; documento, página y referencia; caso de abstención.
R6 · Capas obligatorias	C1–C7/T1–T2 descritas en sección 23; panel de operación como comprobación.	Código modular, puertos/adaptadores, trazas y flujos completos ejecutados.
R7 · API REST	Contrato en sección 23.3; documentación OpenAPI de C1.	Endpoints disponibles, validación, errores HTTP y ejemplos de solicitud/respuesta.
R8 · Presentación web	Las once pantallas consumen únicamente C1 por HTTP.	Inspección de código y red; ninguna llamada web directa a Ollama/vector DB.
R9 · Evaluación	Operación y métricas + banco de pruebas sección 24.	Resultados de RAG, guardrails, caché, enrutador, ciclo de agente y latencias, sin cifras inventadas.
R10 · Reproducibilidad	Repositorio, README, dependencias, modelos y guía de arranque.	Instalación siguiendo instrucciones, corpus autorizado y pruebas automatizadas.
R11 · Informe técnico	Documento final distinto de esta propuesta; diagramas, ADR y resultados medidos.	Informe PDF con vistas, cinco secuencias, seis ADR, tablas, límites y referencias.
R12 · Más allá del chatbot	Mapa de evidencia + informes como función principal; explorador de apoyo.	Matriz, relaciones y síntesis descargable obtenidas de documentos reales con revisión humana.

23 Localización y funcionamiento de cada capa obligatoria

La separación central es «aplicación web → servicio REST → capas del servicio → adaptadores locales». Las dependencias internas deben avanzar en una dirección y atravesar interfaces explícitas; observabilidad y retroalimentación son mecanismos transversales. Esta descomposición adopta la nomenclatura C1–C7/T1–T2 del documento de la asignatura, en lugar de reemplazarla por denominaciones ambiguas.

Capa	Responsabilidad y módulos del producto	Implementación y comprobación
C1 · API	Traduce acciones web (proyectos, documentos, mapa, opiniones) a contratos HTTP; valida esquemas.	servicio/api; OpenAPI, códigos 2xx/4xx/5xx, pruebas de contrato y no acceso directo desde web a modelos.
C2 · Orquestación/agente	Coordina consulta, indexación, extracción y mapa; reformula consulta pobre con límite de iteraciones.	servicio/orquestacion; bucle controlado y traza de iteraciones, salida por éxito/límite/error.
C3 · Guardrails	Entrada: formato/longitud y patrones de inyección o ámbito; salida: esquema y presencia/validez de citas.	servicio/guardrails; al menos dos verificaciones de entrada y dos de salida con acciones definidas.
C4 · Caché	Exacta y semántica para evitar trabajo repetido; depende de corpus, filtros y configuración.	servicio/cache; TTL, umbral medido, invalidación al actualizar/eliminar documentos; pruebas repetidas y parafraseadas.
C5 · Contexto/RAG	Segmentación, embeddings, consulta vectorial, filtros y prompt anclado a fragmentos.	servicio/contexto; variables top-k/umbral documentadas, citas por página y abstención si no hay evidencia.
C6 · Enrutador/gateway	Selecciona al menos dos LLM por tipo/complejidad y ofrece timeout, reintentos y respaldo.	servicio/modelos; matriz de ruteo, registro de modelo, fallback y simulación de fallo controlado.
C7 · Datos/modelos	Adaptadores al servidor Ollama, índice vectorial, documentos, persistencia, caché y logs.	servicio/datos; cambiar un adaptador no altera los casos de uso; pruebas de repositorios.
T1 · Observabilidad	Registro de trazas por petición, métricas por capa, errores, caché y guardrails.	servicio/observabilidad + pantalla Operación; GET /metricas y trace_id verificable.
T2 · Retroalimentación	Útil/no útil y comentario asociados a la ejecución específica y al artefacto resultante.	servicio/retroalimentacion + Validación científica; POST /retroalimentacion y consulta de bitácora.

23.1 Ciclo de operación de un análisis fundamentado

Fase	Conducta esperada y controles
0. Preparación	Seleccionar proyecto y corpus autorizados; persistir versión del índice y perfil de modelos.
1. Recepción	La aplicación web envía POST /mapa-evidencia; C1 valida estructura y genera un identificador correlacionable.
2. Protección	C2 coordina C3 de entrada: bloqueo de instrucciones incompatibles o fuera de alcance; registrar la decisión en T1.
3. Optimización	C4 consulta coincidencia exacta o semántica con versión del corpus, configuración y filtros; un acierto sigue a validación de salida.
4. Recuperación	C6 elige el modelo según criterio probado; C5 busca fragmentos relevantes. C2 puede reformular y repetir con cota explícita.
5. Síntesis	Gateway C6 utiliza C7/Ollama; extracción estructurada y comparación solo con evidencias citables.
6. Validación	C3 de salida revisa esquema, fuentes, sensibilidad y apego al contexto; si no se puede justificar, devolver abstención.
7. Entrega	C1 devuelve matriz, citas, versión, ruta/modelo, uso de caché, guardrails, tiempos e identificador de traza.
8. Revisión	La investigadora aprueba, corrige o rechaza afirmaciones; T2 vincula la opinión con T1; el informe integra solo el estado válido.

23.2 Estructura modular propuesta del repositorio

El código final se organizará en dos contenedores de aplicación claramente separados. La estructura siguiente describe el destino de implementación; no se atribuye su existencia al prototipo actual.

- web/ — interfaz y componentes visuales; cliente HTTP tipado, vistas y manejo de estados.
- servicio/api/ — esquemas, rutas, errores y documentación OpenAPI (C1).
- servicio/orquestacion/ — casos de uso y ciclo de agente acotado (C2).
- servicio/guardrails/ — políticas de entrada y salida con registros de decisión (C3).
- servicio/cache/ — coincidencia exacta, similitud semántica, expiración e invalidación (C4).
- servicio/contexto/ — parser, fragmentación, embeddings, recuperación y prompts (C5).
- servicio/modelos/ — reglas de enrutamiento, gateway, timeouts y fallback (C6).
- servicio/datos/ — clientes Ollama, base vectorial y almacenes con interfaces (C7).
- servicio/observabilidad/ y servicio/retroalimentacion/ — T1 y T2.
- evaluacion/ — casos de prueba, resultados y scripts de comparación.
- docs/ — diagramas, decisiones ADR, políticas y contrato del servicio.

23.3 Contrato HTTP mínimo que deberá funcionar

Método y endpoint	Módulo consumidor	Condición de respuesta y prueba
GET /health	Inicio / Operación	Estado comprobable de servicio, Ollama, base vectorial y caché.
POST /documentos	Biblioteca / Indexación	Alta real, segmentación, embeddings; id y número de fragmentos.
GET /documentos	Biblioteca	Lista indexada con id, nombre, fecha y estado.
DELETE /documentos/{id}	Biblioteca	Retira documento/vector(es) e invalida caché dependiente.
POST /mapa-evidencia	Mapa / Extracción	Artefacto estructurado, citas, modelo/ruta, caché, guardrails, tiempos y traza.
POST /retroalimentacion	Explorador / Validación	Almacena útil/no útil y comentario con trace_id y resultado.
GET /metricas	Operación	Mediciones reales por capa, caché, guardrails, modelos y opiniones.
GET /configuracion	Configuración	Modelos, parámetros y versiones activas.
POST /proyectos, GET /proyectos	Proyectos / Inicio	Extensiones propias de MatriScope para separar investigaciones.
POST /extracciones, POST /validaciones	Extracción / Validación	Extensiones para fichas verificables y revisión humana.
GET /informes/{id}	Informes	Extensión para descargar PDF trazable y versionado.

24 Verificación, documentación y criterios de terminación

El entregable final de clase debe evaluarse con datos obtenidos en el equipo local, no con cifras del prototipo. Los umbrales, tamaños de fragmento, solapamientos, modelos elegidos y política de enrutamiento se definirán mediante experimentos y se consignarán en decisiones arquitectónicas; no se anticipan resultados o comparaciones no efectuadas.

24.1 Diseño de experimentos y pruebas obligatorias

Conjunto o experimento	Ejecución propuesta	Evidencia que irá al informe
Selección de modelos	Comparar al menos dos LLM y dos modelos de embeddings con mismo corpus/preguntas, equipo y versión.	Tabla de fidelidad, relevancia, acierto@k, tiempo, memoria, idioma y licencias.
RAG y artefacto	Al menos 20 casos de prueba con resultado esperado y fuente, con y sin recuperación.	Acierto@k, apego a fuente, relevancia 0–5, comparabilidad y análisis de errores.
Guardrails	Al menos 10 entradas problemáticas y 10 normales; comprobar dos reglas de entrada y dos de salida.	Bloqueos correctos, falsos positivos, decisión de política y ejemplos anonimizados.
Caché	Repetir peticiones idénticas y paráfrasis; actualizar o eliminar corpus y repetir.	Aciertos, reducción de latencia, falsos equivalentes e invalidación.
Enrutador	Preguntas etiquetadas por tipo de operación/complejidad.	Proporción de rutas correctas, elección de modelo y costo de latencia.
Ciclo de agente	Consultas de recuperación inicial insuficiente.	Número de intentos, porcentaje de mejora, condición de salida y límites.
Desempeño y T1/T2	Ejecutar los conjuntos anteriores y recoger trazas y valoraciones.	Latencia media/máxima y por capa; feedback unido a trace_id.

24.2 Vistas, diagramas y decisiones de arquitectura

El informe técnico posterior incorporará cinco vistas estructurales numeradas (contexto, contenedores, componentes, capas y despliegue local) y cinco secuencias trazables al código (ingesta; consulta normal; consulta por caché; bloqueo por guardrail; reformulación por ciclo de agente). Cada diagrama identificará actores, procesos, servicios externos locales, interfaces y puntos de registro T1/T2. Se distinguirá de forma explícita un diagrama de diseño de un flujo ya verificado en ejecución.

Se elaborarán al menos seis registros de decisión de arquitectura (ADR): selección de LLM y embeddings; regla del enrutador; umbral/TTL e invalidación de caché semántica; guardrails y política de fallos; estrategia de fragmentación/recuperación; ciclo de agente y condición de salida. Cada ADR tendrá contexto, alternativas, decisión, evidencia experimental, consecuencias y estado.

24.3 Secuencia de demostración verificable

Paso	Demostración y correspondencia visible
1	Arrancar localmente web, API, Ollama, índice y almacenes; abrir OpenAPI y GET /health.
2	Cargar un artículo autorizado desde Biblioteca, indexarlo y mostrar metadatos/fragmentos.
3	Construir mapa de evidencia; abrir citas y verificar documento/página y trace_id.
4	Repetir la misma solicitud y una paráfrasis, evidenciando la respuesta desde caché y su latencia.
5	Enviar entrada no permitida y mostrar guardrail de entrada/salida y respuesta segura.
6	Usar caso de recuperación insuficiente y exhibir decisión de reformulación del agente y su límite.
7	Registrar retroalimentación y consultar Operación para localizar la traza y sus métricas.
8	Generar informe con solo afirmaciones revisadas; explicar limitaciones y decisiones de modelos.

24.4 Criterio de honestidad científica y de estado de implementación

La interfaz visual y sus capturas son artefactos de diseño e interacción. La presencia de un control, indicador, gráfico o nombre de modelo no confirma que exista un servicio conectado. Los resultados científicos solo podrán publicarse cuando estén respaldados por documentos con permiso de uso, fuente localizable, comparación contextual y revisión humana. Si el sistema carece de evidencia suficiente, mostrará abstención o estado pendiente, nunca un hallazgo fabricado. El informe final declarará el uso de asistentes de IA y las limitaciones del sistema, de acuerdo con la sección 14 del enunciado.

24.5 Fuentes normativas de esta ampliación

Tópicos Selectos de Arquitectura de Software. (2026). Proyecto integrador: producto inteligente en capas con modelos de lenguaje, embeddings y RAG [Documento de asignatura, Unidad II], pp. 4–13. Archivo adjunto: Proyecto_integrador_RAG.pdf.

Tópicos Selectos de Arquitectura de Software. (2026). Rúbrica de evaluación: proyecto integrador con producto inteligente en capas, embeddings y RAG [Documento de asignatura, Unidad II], pp. 1–6. Archivo adjunto: Rubrica_proyecto_integrador_RAG.pdf.

MatriScope. (2026). Capturas del prototipo de interfaz (11 módulos) e identidad gráfica [Material de elaboración del proyecto, sin validación funcional de los componentes de IA]. Las figuras 4–15 reproducen exclusivamente el diseño visual propuesto.

Referencias

Anwar, T. U., Merighe, P., Kancharla, R. R., Kombaiah, B., y Kouraytem, N. (2025). Influence of Process Parameter and Build Rate Variations on Defect Formation in Laser Powder Bed Fusion SS316L. Materials, 18(2), 435. https://doi.org/10.3390/ma18020435

Aziz, U., McAfee, M., Manolakis, I., Timmons, N., y Tormey, D. (2025). A review of optimization of additively manufactured 316/316L stainless steel process parameters, post-processing strategies, and defect mitigation. Materials, 18(12), 2870. https://doi.org/10.3390/ma18122870

Cacace, S., Pagani, L., Colosimo, B. M., y Semeraro, Q. (2022). The effect of energy density and porosity structure on tensile properties of 316L stainless steel produced by laser powder bed fusion. Progress in Additive Manufacturing. https://doi.org/10.1007/s40964-022-00281-y

Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., y Liu, Z. (2024). BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. arXiv:2402.03216. https://arxiv.org/abs/2402.03216

Chroma. (s. f.). Collections. https://cookbook.chromadb.dev/core/collections/

FastAPI. (s. f.). Features. https://fastapi.tiangolo.com/features/

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., y Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. Advances in Neural Information Processing Systems, 33, 9459–9474. https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html

National Institute of Standards and Technology. (2026). Measurement Science for Additive Manufacturing Program. https://www.nist.gov/programs-projects/measurement-science-additive-manufacturing-program

National Library of Medicine. (2025). PMC Copyright Notice. https://pmc.ncbi.nlm.nih.gov/about/copyright/

Ollama. (s. f.). Biblioteca de modelos: llama3.2, qwen2.5, nomic-embed-text y bge-m3. https://ollama.com/library

OWASP Gen AI Security Project. (2025). LLM01 Prompt Injection. https://genai.owasp.org/llmrisk/llm01-prompt-injection/

Stopka, K. S., Desrosiers, A., Andreaco, A., y Sangid, M. D. (2024). A methodology for the rapid qualification of additively manufactured materials based on pore defect structures. Integrating Materials and Manufacturing Innovation, 13, 335–359. https://doi.org/10.1007/s40192-024-00343-9

Tópicos Selectos de Arquitectura de Software. (2026). Proyecto integrador: producto inteligente en capas con modelos de lenguaje, embeddings y RAG. Documento de la asignatura.